



**PREDIKSI HARGA SAHAM PERBANKAN MENGGUNAKAN
MODEL HYBRID LONG SHORT-TERM MEMORY DAN
ANALISIS SENTIMEN LEKSIKON INDONESIA**

SKRIPSI

Sebagai salah satu syarat untuk meraih
Gelar Sarjana

Oleh:

Adrian Halim Danutirta
32220052

Universitas Bunda Mulia
Fakultas Teknologi Dan Desain
Program Studi Informatika
Jakarta
2026

PRAKATA

Puji syukur penulis panjatkan kepada Tuhan Yang Maha Kuasa karena atas kasih karuniaNya, skripsi yang berjudul **“PREDIKSI HARGA SAHAM PERBANKAN MENGGUNAKAN MODEL HYBRID LONG SHORT-TERM MEMORY DAN ANALISIS SENTIMEN LEKSIKON INDONESIA”**. Penyusunan skripsi ini merupakan salah satu syarat untuk memperoleh gelar Sarjana pada jenjang pendidikan Strata Satu (S1).

Dalam penyusunan skripsi ini, hal tersebut tidak lepas dari bantuan, arahan, dan bimbingan oleh banyak pihak yang telah memberi banyak masukan kepada penulis. Oleh karena itu, penulis ingin memberikan ucapan terima kasih kepada semua pihak, khususnya kepada:

1. Bapak Doddy Surja Bajuadji, M.B.A. selaku Rektor Universitas Bunda Mulia.
2. Bapak Howard S. Giam, S.E., Ak., M.B.A. selaku Pelaksana Harian Rektor Universitas Bunda Mulia.
3. Ibu Dr. Shanty Sudarji, S.Psi., M.Psi. selaku Wakil Rektor Bidang Akademik Universitas Bunda Mulia.
4. Bapak Dr. Adhiguna Mahendra, S.kom., M.Sc. selaku Dekan Fakultas Teknologi dan Desain Universitas Bunda Mulia
5. Bapak Agustinus Fritz Wijaya, S.Kom., M.Cs., selaku Ketua Program Studi Teknik Informatika Universitas Bunda Mulia.
6. Ibu Ester Lumba, S.Si, M.Kom. selaku Dosen Pembimbing Akademik yang telah meluangkan waktu, tenaga, dan pikiran untuk memberikan bimbingan serta arahan kepada penulis.

Demikian, penyusunan skripsi ini penulis hadirkan dengan segala kelebihan dan kekurangan akibat keterbatasan ilmu dan kemampuan yang dimiliki.

Jakarta, 06 Desember 2025

Penulis,

Adrian Halim Danutirta

IDENTITAS PENYUSUN

Nama : Adrian Halim Danutirta
Nim : 32220052
Tempat/Tanggal Lahir : Jakarta , 20 November 2004
Jenis Kelamin : Laki-laki
Alamat : Jl.Adhi Karya Gg.H.Arifin No.15E
RT.004/RW.002 Kedoya Sel., Kec. Kb. Jeruk, Kota
Jakarta Barat, Daerah Khusus Ibukota Jakarta 11520
Nomor Telepon : +62 81519171577
Email : adrianhalim1120@gmail.com

Riwayat Pendidikan

2010 – 2016 : SDS Kristen Genesaret
2016 – 2019 : SMP Taman Permata Indah
2019 – 2022 : SMA Taman Permata Indah
2022 – Sekarang : Universitas Bunda Mulia Ancol

DAFTAR ISI

	Halaman
PRAKATA	ii
IDENTITAS PENYUSUN	iv
DAFTAR ISI.....	v
DAFTAR GAMBAR.....	viii
DAFTAR TABEL	ix
BAB 1 PENDAHULUAN	1
1.1 Latar Belakang Permasalahan	1
1.2 Pembatasan Masalah	5
1.3 Rumusan Permasalahan	6
1.4 Tujuan dan Manfaat	7
1.4.1 Tujuan Penelitian	8
1.4.2 Manfaat Penelitian	8
1.5 Sistematika Penulisan.....	9
BAB 2 TINJAUAN PUSTAKA.....	12
2.1 Kerangka Teori.....	12
2.1.1 Pasar Modal dan Saham Perbankan	12
2.1.2 Long Short-Term Memory (LSTM).....	13
2.1.3 Analisis Sentimen dan Lexicon-Based (InSet)	13
2.1.4 Model Hybrid (LSTM dan Sentimen).....	14
2.1.5 Python dan Pustaka Pendukung (<i>Library</i>)	14
2.1.6 Web Scraping	15
2.1.7 Pustaka Sastrawi (<i>Stemming</i> Bahasa Indonesia)	15
2.1.8 <i>Framework</i> Flask	15
2.1.9 Metodologi Machine Learning Development Life Cycle (MLDLC)	16
2.1.9.1 Pengumpulan Data (<i>Data Gathering</i>)	16
2.1.9.2 Persiapan Data (<i>Data Preparation</i>)	17
2.1.9.3 Transformasi Data (<i>Data Wrangling</i>)	17
2.1.9.4 Analisis Data (<i>Data Analysis</i>).....	17
2.1.9.5 Pelatihan Model (<i>Model Training</i>).....	17

2.1.9.6	Pengujian Model (Model Testing)	18
2.1.9.7	Penyebaran Model (Deployment)	18
2.2	Penelitian Terdahulu	18
2.2.1	Kesenjangan Data (<i>Data Gap</i>).	20
2.2.2	Kesenjangan Bahasa (<i>Language Gap</i>).	20
2.2.3	Kesenjangan Metodologi (<i>Methodological Gap</i>).....	20
2.3	Kerangka/Skema Berpikir.....	21
2.3.1	Tahap Input & Pra-pemrosesan (<i>Preprocessing</i>).	21
2.3.2	Tahap Pengembangan Model <i>Hybrid</i>	22
2.3.3	Tahap Output & Evaluasi.....	22
2.3.4	Pengumpulan Data.	24
2.3.5	Sastrawi Stemmer.....	24
2.3.6	InSet Lexicon.	24
2.3.7	Fitur Fusi (<i>Fusion</i>).	25
2.3.8	LSTM Processing.....	25
2.3.9	Validasi Model.....	25
BAB 3	ANALISIS DAN PERANCANGAN.....	27
3.1	Rekayasa Kebutuhan (<i>Requirements Engineering</i>)	27
3.1.1	Kebutuhan Fungsional (<i>Functional Requirements</i>)	27
3.1.2	Kebutuhan Non-Fungsional (<i>Non-Functional Requirements</i>).....	28
3.1.3	Kebutuhan Lingkungan Sistem (Perangkat Keras dan Lunak)	29
3.2	Pemilihan Metode, Teknik, dan Kerangka Kerja.....	30
3.2.1	Metodologi Pengembangan.....	30
3.2.2	Pemilihan Teknik Pemodelan	32
3.2.3	Pemilihan Kerangka Kerja Implementasi	32
3.3	Perancangan Proses	33
3.3.1	Proses Pengumpulan Data (Data Gathering)	34
3.3.2	Proses Persiapan Data (Data Preparation).....	34
3.3.3	Proses Transformasi Data (Data Wrangling)	34
3.3.4	Proses Analisis Data (Data Analysis)	35
3.3.5	Proses Pelatihan Model (Model Training)	35
3.3.6	Proses Pengujian Model (Model Testing).....	35
3.3.7	Proses Penyebaran Model (Deployment).....	35
3.4	Perancangan Sistem	36

3.4.1	Pemodelan Interaksi Pengguna (<i>Use Case Diagram</i>).....	37
3.4.2	Arsitektur Sistem Web Flask	38
3.4.3	Rancangan Antarmuka Pengguna (<i>Wireframe</i>)	39
3.5	Perancangan Pengujian	43
3.5.1	Pengujian Algoritma Pemodelan.....	43
3.5.2	Pengujian Fungsionalitas Sistem.....	44
BAB 4 IMPLEMENTASI DAN PENGUJIAN.....		45
4.1	Implementasi	45
4.1.1	Lingkungan Implementasi.....	46
4.1.2	Implementasi Pengumpulan dan Pra-pemrosesan Data	47
4.1.3	Implementasi Analisis Sentimen dan Data Fusion.....	49
4.1.4	Implementasi Model Baseline LSTM dan Hybrid LSTM	50
4.1.5	Implementasi Dashboard Web Sentilytics	52
4.2	Pengujian.....	57
4.2.1	Pengujian Model Prediksi	58
4.2.2	Hasil Evaluasi RMSE, MAE, dan MAPE.....	58
4.2.3	Pengujian Fungsionalitas Sistem.....	59
4.2.4	Pembahasan Hasil Pengujian	62
DAFTAR PUSTAKA		64
LAMPIRAN.....		66

DAFTAR GAMBAR

Gambar 2.1 Kerangka Berfikir.....	23
Gambar 3.1 Flowchart Sistem Sentilytics.....	33
Gambar 3.2 Use Case Diagram Sistem Sentilytics	38
Gambar 3.3 <i>Wireframe Login Page</i>	39
Gambar 3.4 <i>Wireframe Dashboard Utama</i>	40
Gambar 3.5 <i>Wireframe Admin Panel</i>	41
Gambar 3.6 <i>Wireframe Model Evaluation</i>	41
Gambar 3.7 <i>Wireframe Forecast Simulation H+7</i>	42
Gambar 3.8 <i>Wireframe Dataset Summary</i>	43
Gambar 4.1 Implementasi Antarmuka Halaman Login	54
Gambar 4.2 Implementasi Antarmuka Dashboard Utama	54
Gambar 4.3 Implementasi Antarmuka Halaman Admin Panel.....	55
Gambar 4.4 Implementasi Antarmuka Halaman Model Evaluation.....	55
Gambar 4.5 Implementasi Antarmuka Halaman Forecast Simulation H+7	56
Gambar 4.6 Implementasi Antarmuka Halaman Dataset Summary	57

DAFTAR TABEL

Tabel 2.1 Penelitian Terdahulu	19
Tabel 3.1 Rancangan Hyperparameter Awal Model LSTM	36
Tabel 4.1 Spesifikasi Perangkat Keras.....	46
Tabel 4.2 Spesifikasi Perangkat Lunak.....	46
Tabel 4.3 Jumlah Data Berita Berdasarkan Sumber dan Emiten	48
Tabel 4.4 Contoh Pra-pemrosesan Teks Berita.....	49
Tabel 4.5 Ringkasan Sentimen Harian.....	49
Tabel 4.6 Ringkasan Dataset Fusion.....	50
Tabel 4.7 Struktur Dataset Fusion.....	50
Tabel 4.8 Perbandingan Fitur Input Model	51
Tabel 4.9 Konfigurasi Parameter Model LSTM	51
Tabel 4.10 Fitur Aplikasi Web Sentilytics.....	53
Tabel 4.11 Hasil Evaluasi Model Baseline LSTM dan Hybrid LSTM.....	58
Tabel 4.12 Hasil Pengujian Black-Box Aplikasi Sentilytics	60

BAB 1

PENDAHULUAN

1.1 Latar Belakang Permasalahan

Pasar modal Indonesia telah mengalami transformasi yang signifikan dalam satu dekade terakhir, menjadi salah satu indikator utama stabilitas ekonomi nasional dan daya tarik investasi di kawasan Asia Tenggara. Dalam ekosistem pasar modal yang dinamis ini, sektor perbankan memegang peranan yang sangat vital, sering kali disebut sebagai tulang punggung Indeks Harga Saham Gabungan (IHSG).

Saham-saham berkapitalisasi besar (*big cap*) atau *blue chip* di sektor ini, khususnya PT Bank Central Asia Tbk (BBCA) dan PT Bank Rakyat Indonesia (Persero) Tbk (BBRI), tidak hanya mendominasi volume perdagangan harian tetapi juga memiliki korelasi yang kuat dengan sentimen ekonomi makro. Volatilitas harga saham pada kedua emiten ini sering kali menjadi proksi bagi kesehatan pasar secara keseluruhan. Namun, pergerakan harga saham ini tidaklah bergerak dalam ruang hampa; ia adalah resultan dari interaksi kompleks antara kinerja fundamental perusahaan dan persepsi pasar.

Sering kali terjadi fenomena di mana harga saham mengalami tekanan jual (*net sell*) masif dari investor asing meskipun fundamental perbankan tetap solid. Fenomena ini kerap dipicu oleh sentimen eksternal, seperti perubahan peringkat rekomendasi oleh sekuritas asing, kebijakan suku bunga, atau ketidakpastian geopolitik global yang memicu aksi *profit taking* (Indo Premier Sekuritas, 2025; Bloomberg Technoz, 2025). Kejadian berulang seperti ini membuktikan bahwa analisis pergerakan harga saham tidak bisa lagi hanya didominasi oleh dua mazhab utama tradisional: analisis fundamental dan analisis teknikal.

Analisis fundamental berfokus pada nilai intrinsik perusahaan melalui laporan keuangan, rasio profitabilitas, dan kebijakan dividen. Sementara itu, analisis teknikal mengandalkan data historis harga (*Open, High, Low, Close, Volume*) untuk memprediksi tren masa depan dengan asumsi bahwa "sejarah akan berulang" (*history repeats itself*). Meskipun metode teknikal telah digunakan secara luas, pendekatan ini memiliki keterbatasan mendasar: ia sering kali gagal menangkap fluktuasi harga yang disebabkan oleh lonjakan sentimen pasar yang bersifat tiba-tiba (*shock*) dan non-linear. Pasar saham sangat rentan terhadap informasi eksternal, mulai dari kebijakan suku bunga Bank Indonesia, ketegangan geopolitik global, hingga berita korporasi spesifik yang beredar di media massa.

Dalam konteks perilaku pasar (*behavioral finance*), keputusan investor tidak selalu rasional. Pasar modal Indonesia yang didominasi oleh investor ritel sangat rentan terhadap bias perilaku seperti *Herd Behavior* (ikut-ikutan) dan *Overreaction* atau reaksi berlebihan (Frensidy, 2023). Emosi, ketakutan, dan keserakahan (*fear and greed*) sering kali mendikte aksi jual atau beli massal yang tidak terdeteksi hanya dengan melihat grafik pergerakan harga masa lalu (Bareksa, 2024). Fenomena ini menegaskan bahwa data deret waktu (*time-series*) harga saham semata tidak cukup untuk membangun model prediksi yang *robust* atau tangguh. Diperlukan integrasi dimensi data lain yang mampu merepresentasikan psikologi pasar secara *real-time*, yaitu data tekstual dari berita keuangan.

Perkembangan pesat dalam bidang Kecerdasan Buatan (*Artificial Intelligence*) dan Pembelajaran Mendalam (*Deep Learning*) menawarkan solusi untuk tantangan ini. Dalam beberapa tahun terakhir, adopsi AI dalam sektor keuangan Indonesia semakin masif, tidak hanya untuk otomatisasi tetapi juga untuk

analisis risiko berbasis sentimen berita secara *real-time* (Inixindo Jogja, 2025). *Long Short-Term Memory* (LSTM), sebuah varian arsitektur dari *Recurrent Neural Network* (RNN), telah muncul sebagai standar industri dalam pemrosesan data deret waktu. Keunggulan utama LSTM terletak pada mekanisme gerbang (*gating mechanism*) terdiri dari *input gate*, *forget gate*, dan *output gate* yang memungkinkannya untuk mempelajari ketergantungan jangka panjang (*long-term dependencies*) dan mengatasi masalah *vanishing gradient* yang sering melumpuhkan model RNN konvensional.

Penelitian terdahulu menunjukkan bahwa LSTM secara konsisten mengungguli metode statistik klasik seperti ARIMA maupun metode *machine learning* konvensional seperti *Support Vector Regression* (SVR) dalam memprediksi volatilitas aset keuangan. Namun, meskipun LSTM memiliki kemampuan superior dalam memodelkan pola numerik, model ini tetap memiliki "titik buta" jika hanya dilatih menggunakan data historis harga. Sebuah saham bisa saja menunjukkan tren teknikal naik (*bullish*) yang kuat, namun rilis berita negatif tentang lonjakan *Non-Performing Loan* (NPL) atau isu regulasi perbankan dapat seketika membalikkan tren tersebut menjadi turun (*bearish*). Oleh karena itu, pendekatan *Hybrid* yang menggabungkan analisis kuantitatif (harga historis) dan analisis kualitatif (sentimen berita) menjadi sebuah kebutuhan mendesak untuk meningkatkan akurasi prediksi.

Analisis Sentimen (*Sentiment Analysis*), sebagai bagian dari *Natural Language Processing* (NLP), memungkinkan ekstraksi opini dan polaritas emosi dari teks berita keuangan yang tidak terstruktur. Dengan mengonversi teks berita menjadi skor sentimen kuantitatif (positif, negatif, atau netral), informasi kualitatif

ini dapat difusikan ke dalam jaringan syaraf tiruan sebagai fitur tambahan. Tantangan utama dalam konteks pasar Indonesia adalah kompleksitas bahasa. Berbeda dengan Bahasa Inggris yang memiliki sumber daya NLP melimpah seperti VADER atau TextBlob, analisis sentimen Bahasa Indonesia memerlukan penanganan khusus, terutama terkait penggunaan kamus (*lexicon*) yang relevan dengan domain keuangan. Penggunaan kamus seperti InSet (*Indonesian Sentiment Lexicon*) atau Sastrawi menjadi krusial untuk memastikan akurasi deteksi sentimen.

Penelitian ini mengusulkan pengembangan model prediksi harga saham *Hybrid* yang mengintegrasikan kekuatan LSTM dalam memproses data *time-series* dengan kekuatan Analisis Sentimen Berita Keuangan. Studi kasus difokuskan pada saham BBKA dan BBRI mengingat likuiditas dan sensitivitasnya yang tinggi terhadap berita. Berita-berita terkait kinerja keuangan kuartalan, pembagian dividen, hingga isu makroekonomi seperti fluktuasi nilai tukar Rupiah, diasumsikan memiliki pengaruh terhadap pergerakan harga penutupan saham. Dengan menggabungkan kedua aliran data ini, diharapkan model yang dihasilkan tidak hanya mampu "melihat" pola harga masa lalu, tetapi juga mampu "membaca" konteks situasi pasar saat ini, sehingga menghasilkan prediksi yang lebih akurat dan adaptif terhadap dinamika pasar modal Indonesia.

Urgensi penelitian ini juga didorong oleh kesenjangan (*gap*) pada penelitian sebelumnya. Sebagian besar studi prediksi saham di Indonesia masih terfragmentasi: fokus hanya pada aspek teknikal murni menggunakan algoritma *deep learning*, atau fokus pada analisis sentimen media sosial (seperti Twitter/X dan YouTube) yang sering kali mengandung *noise* tinggi dan tidak terstruktur. Masih sedikit penelitian yang secara komprehensif mengintegrasikan berita

keuangan formal dari portal berita terpercaya dengan metode *Lexicon-Based* yang spesifik untuk Bahasa Indonesia ke dalam arsitektur LSTM untuk emiten perbankan *blue chip*. Oleh karena itu, penelitian ini hadir untuk mengisi kekosongan tersebut dengan menawarkan pendekatan *hybrid* yang lebih terstruktur dan berorientasi pada data berkualitas tinggi.

1.2 Pembatasan Masalah

Agar penelitian lebih terarah dan mendalam, penulis menetapkan batasan masalah sebagai berikut:

1. Objek penelitian difokuskan pada saham sektor perbankan, yaitu PT Bank Central Asia Tbk (BBCA) dan PT Bank Rakyat Indonesia (Persero) Tbk (BBRI). Pemilihan kedua emiten tersebut didasarkan pada karakteristiknya sebagai saham perbankan berkapitalisasi besar, memiliki likuiditas tinggi, serta memiliki intensitas pemberitaan yang relatif tinggi di media keuangan nasional.
2. Data harga saham yang digunakan berupa data historis harian dengan atribut Open, High, Low, Close, dan Volume (OHLCV). Data tersebut diperoleh melalui Yahoo Finance/yfinance pada periode 1 Januari 2023 sampai 31 Desember 2024.
3. Data berita keuangan yang digunakan berasal dari portal berita CNBC Indonesia dan Kontan. Data teks yang digunakan dalam proses analisis sentimen dibatasi pada judul berita dan ringkasan berita apabila tersedia. Apabila ringkasan tidak tersedia, sistem hanya menggunakan judul berita sebagai sumber teks sentimen.

4. Penelitian ini menggunakan algoritma Long Short-Term Memory (LSTM) untuk memprediksi harga penutupan saham dan pendekatan Lexicon-Based dengan kamus InSet untuk menghasilkan skor sentimen berita. Penelitian ini tidak melakukan fine-tuning model bahasa besar atau Large Language Model (LLM). Perbandingan model dilakukan antara Baseline LSTM yang menggunakan fitur OHLCV dan Hybrid LSTM yang menggabungkan fitur OHLCV dengan skor sentimen berita.
5. Target prediksi utama dalam evaluasi model adalah harga penutupan saham pada hari perdagangan berikutnya (Close Price H+1). Evaluasi akurasi utama dilakukan pada prediksi H+1 karena hasil prediksi dapat dibandingkan langsung dengan data aktual pada data uji historis. Selain itu, aplikasi Flask menyediakan fitur simulasi forecast sampai H+7 untuk menunjukkan kemampuan sistem dalam melakukan proyeksi beberapa hari perdagangan ke depan. Namun, hasil forecast H+2 sampai H+7 tidak dijadikan dasar utama evaluasi akurasi model, melainkan digunakan sebagai fitur visualisasi tambahan. Evaluasi akurasi utama dilakukan menggunakan metrik RMSE, MAE, dan MAPE pada data uji historis.

1.3 Rumusan Permasalahan

Berdasarkan latar belakang di atas, rumusan masalah dalam penelitian ini adalah:

1. Bagaimana merancang dataset multivariat yang menggabungkan data harga saham harian dan skor sentimen berita keuangan untuk prediksi harga saham BBKA dan BBRI?

2. Bagaimana menerapkan analisis sentimen berbasis InSet Lexicon terhadap judul dan ringkasan berita keuangan berbahasa Indonesia sehingga menghasilkan skor sentimen harian?
3. Bagaimana membangun model Baseline LSTM dan Hybrid LSTM untuk memprediksi harga penutupan saham hari perdagangan berikutnya atau Close Price H+1?
4. Bagaimana perbandingan kinerja model Baseline LSTM dan Hybrid LSTM berdasarkan metrik RMSE, MAE, dan MAPE?
5. Bagaimana merancang dan mengimplementasikan prototipe aplikasi web berbasis Flask untuk menampilkan hasil prediksi, grafik aktual dibandingkan prediksi, nilai evaluasi model, serta simulasi forecast sampai tujuh hari perdagangan ke depan?

1.4 Tujuan dan Manfaat

Berdasarkan rumusan permasalahan yang telah dijelaskan sebelumnya, bagian ini menguraikan tujuan yang ingin dicapai dalam penelitian serta manfaat yang diharapkan dari hasil penelitian. Tujuan penelitian disusun untuk menjawab permasalahan terkait perancangan dataset multivariat, penerapan analisis sentimen berbasis InSet Lexicon, pembangunan model Baseline LSTM dan Hybrid LSTM, evaluasi model, serta implementasi prototipe aplikasi web berbasis Flask. Sementara itu, manfaat penelitian dijelaskan dari sisi akademis dan praktis.

1.4.1 Tujuan Penelitian

Penelitian ini bertujuan untuk mengembangkan sebuah sistem prediksi harga saham yang adaptif dan akurat dengan memanfaatkan sinergi antara data pasar dan data berita. Secara spesifik, tujuan operasional penelitian ini adalah:

1. Pengembangan Model: Menghasilkan model prediksi harga saham berbasis algoritma LSTM yang dilatih menggunakan dataset gabungan (*multivariat*) untuk emiten perbankan Indonesia.
2. Implementasi NLP: Menerapkan pipeline pemrosesan teks otomatis yang mencakup Web Scraping, Cleaning, Stemming (Sastrawi), dan Sentiment Scoring (InSet) untuk mengonversi berita kualitatif menjadi data kuantitatif.
3. Menguji dan membandingkan kinerja Model Hybrid LSTM dengan Model Baseline LSTM untuk mengetahui apakah penambahan fitur sentimen berita dapat menurunkan tingkat kesalahan prediksi harga penutupan saham berdasarkan metrik evaluasi yang digunakan.
4. Evaluasi Kinerja: Menyediakan evaluasi kinerja model menggunakan metrik RMSE, MAE, dan MAPE untuk mengukur tingkat kesalahan prediksi serta membandingkan performa Model Baseline LSTM dan Model Hybrid LSTM.
5. Mengimplementasikan hasil model prediksi ke dalam prototipe aplikasi web berbasis Flask yang mampu menampilkan grafik aktual dibandingkan prediksi, nilai metrik evaluasi, serta simulasi prediksi sampai tujuh hari perdagangan ke depan.

1.4.2 Manfaat Penelitian

Penelitian ini diharapkan dapat memberikan kontribusi baik secara teoretis maupun praktis:

1. Manfaat Teoretis (Akademis):

- Memperkaya literatur di bidang *Financial Technology* dan *Artificial Intelligence*, khususnya mengenai penerapan metode *Deep Learning* pada pasar saham negara berkembang (*emerging market*) seperti Indonesia yang memiliki karakteristik volatilitas unik.
- Memberikan bukti empiris baru mengenai validitas dan efektivitas penggunaan metode Lexicon-Based (InSet) dalam analisis sentimen teks keuangan formal berbahasa Indonesia, area yang masih relatif jarang dieksplorasi dibandingkan sentimen media sosial.

2. Manfaat Praktis:

- Bagi Pengguna Sistem: Menyediakan prototipe aplikasi web yang dapat menampilkan hasil prediksi harga saham, grafik aktual dibandingkan prediksi, dan nilai evaluasi model sebagai media analisis berbasis data. Sistem ini tidak dimaksudkan sebagai rekomendasi investasi, melainkan sebagai penerapan Artificial Intelligence pada data pasar modal.
- Bagi Pengembang Teknologi: Menjadi referensi teknis mengenai arsitektur integrasi data terstruktur (*time-series*) dan tidak terstruktur (*text*) menggunakan Python.
- Bagi Emiten Perbankan: Memberikan wawasan mengenai bagaimana pemberitaan media massa memengaruhi persepsi pasar dan valuasi saham perusahaan secara kuantitatif.

1.5 Sistematika Penulisan

Untuk mempermudah pemahaman dan penelaahan, laporan skripsi ini disusun dengan sistematika sebagai berikut:

BAB I: PENDAHULUAN Bab ini memaparkan latar belakang masalah, identifikasi dan pembatasan masalah, rumusan masalah, tujuan dan manfaat penelitian, serta sistematika penulisan laporan.

BAB II: TINJAUAN PUSTAKA Bab ini menguraikan tinjauan pustaka yang mencakup teori-teori dasar tentang pasar modal, algoritma LSTM, Analisis Sentimen berbasis leksikon, penelitian-penelitian terdahulu yang relevan, serta kerangka berpikir penelitian.

BAB III: ANALISIS DAN PERANCANGAN Bab ini menjelaskan metodologi Machine Learning Development Life Cycle (MLDLC) yang digunakan. Pembahasan mencakup 7 tahapan utama, mulai dari Pengumpulan Data (Data Gathering), Persiapan Data (Data Preparation), Transformasi Data (Data Wrangling), Analisis Data (Data Analysis), Pelatihan Model (Model Training), Pengujian Model (Model Testing), hingga Penyebaran Model (Deployment).

BAB IV: IMPLEMENTASI DAN PENGUJIAN Bab ini menguraikan realisasi dari rancangan sistem ke dalam bentuk kode program dan implementasi model kecerdasan buatan. Selanjutnya, dilakukan pengujian model prediksi menggunakan metrik RMSE, MAE, dan MAPE, serta pengujian fungsionalitas aplikasi web secara keseluruhan.

BAB V: SIMPULAN DAN SARAN Bab ini berisi kesimpulan yang ditarik dari seluruh hasil analisis dan pengujian yang telah dilakukan, serta memberikan saran-

saran konstruktif bagi pengembangan penelitian selanjutnya di masa yang akan datang.

BAB 2

TINJAUAN PUSTAKA

2.1 Kerangka Teori

Landasan teori merupakan fondasi ilmiah yang digunakan untuk membedah permasalahan dan merancang solusi dalam penelitian ini. Bagian ini membahas secara mendalam konsep-konsep fundamental yang mendukung pengembangan sistem prediksi harga saham *hybrid*.

2.1.1 Pasar Modal dan Saham Perbankan

Pasar modal merupakan sarana pendanaan bagi perusahaan maupun institusi lain (pemerintah), dan sebagai sarana bagi kegiatan berinvestasi. Di Indonesia, sektor perbankan memiliki kapitalisasi pasar yang dominan. Saham seperti PT Bank Central Asia Tbk (BBCA) dan PT Bank Rakyat Indonesia (Persero) Tbk (BBRI) dikategorikan sebagai saham *Blue Chip* yang memiliki likuiditas tinggi dan fundamental kuat (KB Valbury Sekuritas, 2025). Pergerakan harga saham ini tidak hanya dipengaruhi oleh kinerja internal perusahaan, tetapi juga sentimen eksternal seperti kondisi geopolitik dan kebijakan moneter global (Kementerian Keuangan RI, 2025).

Dalam perspektif *Behavioral Finance*, investor sering kali bertindak tidak rasional. Keputusan investasi kerap dipengaruhi oleh psikologi pasar atau sentimen yang terbentuk dari arus informasi berita. Hal ini sejalan dengan temuan Saputra dan Koesrindartoto (2024) yang menyatakan bahwa sentimen investor memiliki korelasi signifikan terhadap volatilitas harga saham di pasar *emerging market* seperti Indonesia.

2.1.2 Long Short-Term Memory (LSTM)

Long Short-Term Memory (LSTM) adalah pengembangan dari arsitektur *Recurrent Neural Network* (RNN) yang dirancang untuk mengatasi masalah *vanishing gradient* pada data deret waktu (*time-series*) yang panjang. Menurut Chaudhary dan Solanki (2025), LSTM memiliki keunggulan dalam mempelajari *long-term dependencies* melalui mekanisme gerbang (*gating*) yang terdiri dari *input gate*, *forget gate*, dan *output gate*.

Arsitektur ini memungkinkan model untuk memilah informasi mana yang relevan untuk disimpan dan mana yang harus dilupakan dari data historis harga saham. Kemampuan ini membuat LSTM lebih unggul dibandingkan metode statistik klasik seperti ARIMA dalam menangani data keuangan yang bersifat non-linear dan dinamis (Liagkouras & Metaxiotis, 2023).

2.1.3 Analisis Sentimen dan Lexicon-Based (InSet)

Analisis sentimen merupakan cabang dari *Natural Language Processing* (NLP) yang bertujuan untuk mengidentifikasi polaritas opini dalam teks. Untuk teks berbahasa Indonesia, tantangan utamanya adalah struktur bahasa dan penggunaan istilah lokal. Pendekatan *Lexicon-Based* dinilai efisien karena tidak memerlukan data latih yang besar.

Penelitian ini menggunakan kamus InSet (Indonesian Sentiment Lexicon), yaitu metode *Lexicon Based* yang menggunakan kamus kata berbahasa Indonesia sehingga mempermudah kegiatan ekstraksi data teks karena tidak perlu lagi melakukan penerjemahan (Artana et al., 2023). InSet memiliki ribuan kata yang telah diberi bobot positif dan negatif, yang terbukti lebih akurat untuk konteks bahasa Indonesia dibandingkan penerjemahan kamus bahasa Inggris. Sebelum

pembobotan, proses *preprocessing* menggunakan pustaka Sastrawi untuk melakukan *stemming* (pengubahan kata ke bentuk dasar) guna meningkatkan kecocokan kata dengan kamus leksikon. Sebelum pembobotan, proses *preprocessing* menggunakan pustaka Sastrawi untuk melakukan *stemming* (pengubahan kata ke bentuk dasar) guna meningkatkan kecocokan kata dengan kamus leksikon (Abrar et al., 2023).

2.1.4 Model Hybrid (LSTM dan Sentimen)

Model *Hybrid* menggabungkan data kuantitatif (harga historis) dan kualitatif (skor sentimen). Penelitian Joddy (2025) menunjukkan bahwa meskipun LSTM murni memiliki akurasi tinggi, penggabungan metode lain diperlukan untuk menangkap anomali pasar. Integrasi sentimen berita ke dalam LSTM bertujuan untuk memberikan konteks "penyebab" di balik pergerakan angka, sehingga prediksi menjadi lebih adaptif terhadap berita mendadak (*breaking news*).

2.1.5 Python dan Pustaka Pendukung (*Library*)

Python adalah bahasa pemrograman tingkat tinggi yang saat ini menjadi standar industri dalam pengembangan kecerdasan buatan (*Artificial Intelligence*) dan *Data Science*. Keunggulan utama Python terletak pada sintaksnya yang sederhana serta ekosistem pustaka (*library*) yang sangat luas dan bersifat *open-source*. Dalam pengembangan model prediksi, pustaka pemrosesan data seperti *Pandas* dan kerangka kerja *Machine Learning* seperti *TensorFlow/Keras* digunakan secara luas untuk merancang bangun arsitektur jaringan saraf tiruan yang kompleks (Susilowati, & Kusmintarti, 2024).

2.1.6 Web Scraping

Web scraping merupakan teknik komputasi untuk mengekstraksi informasi dan data dari sebuah situs web secara otomatis. Proses ini melibatkan pengunduhan halaman web dan pemrosesan struktur kode (seperti HTML atau XML) untuk mengambil teks spesifik yang dibutuhkan. Dalam penelitian analisis sentimen, *web scraping* menjadi alat desain yang sangat krusial untuk mengumpulkan himpunan data (*dataset*) berupa teks berita secara masif dari portal berita keuangan tanpa harus melakukan penyalinan data secara manual (Najiah, 2023).

2.1.7 Pustaka Sastrawi (*Stemming Bahasa Indonesia*)

Sastrawi adalah pustaka berbasis Python yang dirancang secara khusus untuk memproses teks berbahasa Indonesia. Fungsi utama dari pustaka Sastrawi adalah *stemming*, yaitu tahapan *preprocessing* untuk mereduksi kata yang memiliki imbuhan (prefiks, sufiks, konfiks) menjadi bentuk kata dasarnya sesuai dengan tata bahasa baku Kamus Besar Bahasa Indonesia (KBBI). Proses reduksi ini diimplementasikan agar variasi kata dalam teks berita dapat dicocokkan secara akurat dengan entri kata dasar yang terdapat pada kamus sentimen leksikon (Amaliah & Nuryana, 2022).

2.1.8 Framework Flask

Dalam tahapan implementasi produk perangkat lunak, model prediksi (*Machine Learning*) yang telah dilatih membutuhkan sebuah antarmuka agar dapat berinteraksi dengan pengguna. Untuk menjembatani kebutuhan ini, digunakan Flask, yaitu sebuah *micro web framework* berbasis bahasa pemrograman Python. Flask dipilih karena arsitekturnya yang ringan, fleksibel, dan sangat kompatibel

untuk diintegrasikan dengan pustaka pemrosesan data seperti *TensorFlow/Keras* dan *Scikit-Learn*.

Dalam pengembangan sistem berbasis Kecerdasan Buatan, Flask bertugas sebagai *backend server* atau *Application Programming Interface* (API) yang menerima data *input* dari pengguna melalui halaman *frontend* (HTML/CSS/JavaScript), memproses data tersebut ke dalam model prediktif, lalu mengembalikan *output* hasil prediksi secara *real-time* ke layar pengguna. Kemampuannya dalam menangani *routing* dan *deployment* model menjadikannya standar industri yang tangguh untuk perekayasaan perangkat lunak berskala menengah (Suherlan et al., 2025).

2.1.9 Metodologi Machine Learning Development Life Cycle (MLDLC)

Metodologi penelitian yang digunakan untuk mengembangkan model kecerdasan buatan dalam penelitian ini mengacu pada kerangka kerja Machine Learning Lifecycle. Metodologi ini dipilih karena pendekatannya secara terperinci memetakan siklus hidup pengembangan perangkat lunak berbasis Kecerdasan Buatan mulai dari pengelolaan data mentah hingga implementasi sistem fungsional (Krichen et al., 2022).

Berdasarkan kerangka kerja tersebut, siklus hidup pengembangan sistem dibagi menjadi tujuh tahapan utama:

2.1.9.1 Pengumpulan Data (*Data Gathering*)

Tahap awal yang berfokus pada identifikasi dan ekstraksi data dari berbagai sumber. Dalam penelitian ini, tahap ini mencakup proses penarikan data historis

harga saham secara otomatis melalui API Yahoo Finance, serta pengumpulan teks berita keuangan dari portal berita menggunakan teknik web scraping.

2.1.9.2 Persiapan Data (*Data Preparation*)

Fase untuk mempersiapkan data agar siap diproses. Pada tahap ini, teks berita melalui proses pembersihan bahasa alami (NLP) dengan menghilangkan karakter tidak relevan, sedangkan data deret waktu harga saham dibersihkan dari nilai yang kosong.

2.1.9.3 Transformasi Data (*Data Wrangling*)

Fase pengubahan bentuk data mentah menjadi format yang dapat dipahami oleh mesin. Data teks dipotong menjadi kata dasar (stemming) menggunakan pustaka Sastrawi lalu dikonversi menjadi bobot sentimen menggunakan InSet Lexicon. Data harga saham dinormalisasi menggunakan rentang skala MinMax Scaler.

2.1.9.4 Analisis Data (*Data Analysis*)

Tahap eksplorasi untuk memahami karakteristik himpunan data sebelum dimasukkan ke dalam model. Pada tahap ini, sistem melakukan penyatuan data (Data Fusion) yang menggabungkan matriks harga saham dengan skor sentimen harian, serta menangani imputasi sentimen netral pada tanggal tanpa berita.

2.1.9.5 Pelatihan Model (*Model Training*)

Tahap di mana arsitektur komputasi dirancang, dibangun, dan dilatih menggunakan himpunan data latih. Algoritma Long Short-Term Memory (LSTM) diterapkan untuk melatih jaringan saraf tiruan agar mengenali pola pergerakan harga saham, menghasilkan skenario Model Baseline dan Model Hybrid.

2.1.9.6 Pengujian Model (Model Testing)

Tahap pengujian performa model secara matematis menggunakan data uji (test set) untuk mengukur tingkat kesalahan prediksi. Metrik evaluasi yang digunakan meliputi Root Mean Square Error (RMSE), Mean Absolute Error (MAE), dan Mean Absolute Percentage Error (MAPE).

2.1.9.7 Penyebaran Model (Deployment)

Tahap akhir di mana model yang telah divalidasi diimplementasikan ke dalam lingkungan operasional. Model LSTM yang sudah dilatih disematkan ke dalam aplikasi web Sentilytics menggunakan framework Flask agar pengguna dapat berinteraksi dan melihat hasil komputasinya.

2.2 Penelitian Terdahulu

Penelitian mengenai prediksi harga saham telah mengalami evolusi yang signifikan, mulai dari penggunaan analisis teknikal konvensional hingga penerapan *Deep Learning* yang kompleks. Dalam beberapa tahun terakhir, fokus penelitian mulai bergeser pada pendekatan *Hybrid* yang menggabungkan data numerik pasar dengan data tekstual tidak terstruktur.

Berikut adalah pemetaan penelitian terdahulu yang relevan dengan topik prediksi saham dan analisis sentimen yang menjadi acuan utama dalam penelitian ini:

Tabel 2.1 Penelitian Terdahulu

No	Peneliti & Tahun	Judul Penelitian	Metode & Hasil Utama	Persamaan & Perbedaan
1	Joddy (2025)	Comparative Analysis of CNN, LSTM, and Hybrid CNN-LSTM for Indonesian Stock Prediction.	Metode: Membandingkan kinerja CNN, LSTM, dan Hybrid CNN-LSTM menggunakan data historis saham IDX30. Hasil: Model LSTM murni justru menghasilkan <i>error</i> terendah (RMSE 0.0222) dibandingkan model hybrid yang lebih kompleks.	Persamaan: Sama-sama menggunakan algoritma LSTM sebagai <i>core model</i> untuk prediksi saham di Indonesia. Perbedaan: Joddy hanya menggunakan variabel teknikal (OHLCV). Penelitian ini menambahkan variabel fundamental kualitatif berupa sentimen berita.
2	Saputra & Koesrindartoto (2024)	Pemanfaatan Analisis Sentimen dalam Prediksi Harga Saham: Studi pada Investor Retail Indonesia	Metode: Menggunakan Bi-LSTM dengan fitur tambahan sentimen yang diekstraksi dari komentar YouTube. Hasil: Menunjukkan bahwa penambahan fitur sentimen mampu meningkatkan akurasi dibandingkan model <i>baseline</i>.	Persamaan: Fokus pada pembuktian bahwa sentimen investor mempengaruhi pergerakan harga. Perbedaan: Sumber data sentimen mereka berasal dari media sosial (YouTube) yang memiliki tingkat <i>noise</i> tinggi. Penelitian ini menggunakan portal berita keuangan formal yang lebih terpercaya.
3	Chaudhary & Solanki (2025)	Advanced Stock Market Prediction Using LSTM Networks	Metode: Menggabungkan LSTM dengan sentimen berita global menggunakan leksikon VADER. Hasil: Mencapai tingkat akurasi tinggi dengan MAPE 2.72% pada saham teknologi AS (Apple/Google).	Persamaan: Menggunakan arsitektur <i>Hybrid</i> (LSTM + Sentimen Berita). Perbedaan: Penelitian ini menggunakan VADER yang didesain untuk Bahasa Inggris. Penelitian ini menggunakan InSet Lexicon yang spesifik untuk Bahasa Indonesia agar lebih akurat menangkap konteks lokal.

No	Peneliti & Tahun	Judul Penelitian	Metode & Hasil Utama	Persamaan & Perbedaan
4	Liagkouras & Metaxiotis (2023)	A Hybrid LSTM and Sentiment Analysis System for Stock Market Forecasting	Metode: Mengusulkan sistem <i>hybrid</i> untuk memprediksi arah pergerakan pasar. Hasil: Sistem mampu mengklasifikasikan tren pasar (naik/turun) dengan baik.	Persamaan: Integrasi data teks dan harga historis. Perbedaan: Mereka berfokus pada Klasifikasi (arah harga), sedangkan penelitian ini berfokus pada Regresi (memprediksi nilai harga penutupan secara eksak dalam Rupiah).

Kebaruan (*Novelty*) Penelitian

Berdasarkan pemetaan pada Tabel 2.1, ditemukan beberapa kesenjangan (*research gap*) yang mendasari urgensi penelitian ini:

2.2.1 Kesenjangan Data (*Data Gap*).

Penelitian Saputra (2024) menggunakan data media sosial yang cenderung bias dan tidak terstruktur. Penelitian ini mengisi celah tersebut dengan menggunakan Berita Keuangan Formal yang memiliki kredibilitas lebih tinggi dalam mencerminkan kondisi makroekonomi.

2.2.2 Kesenjangan Bahasa (*Language Gap*).

Mayoritas penelitian *hybrid* seperti Chaudhary (2025) menggunakan kamus sentimen Bahasa Inggris (VADER/TextBlob). Penelitian ini menawarkan kebaruan dengan menerapkan InSet Lexicon, sumber daya linguistik yang dibangun khusus untuk menangkap nuansa sentimen dalam Bahasa Indonesia.

2.2.3 Kesenjangan Metodologi (*Methodological Gap*).

Berbeda dengan Mezghani (2023) yang hanya memprediksi arah tren, penelitian ini bertujuan melakukan prediksi harga secara presisi (*forecasting*)

menggunakan arsitektur LSTM yang telah terbukti superior pada data saham Indonesia (Joddy, 2025).

Dengan demikian, posisi penelitian ini adalah menyempurnakan pendekatan-pendekatan sebelumnya dengan mengintegrasikan Model LSTM, Data Berita Formal, dan Leksikon Bahasa Indonesia (InSet) ke dalam satu arsitektur *Hybrid* yang utuh untuk studi kasus perbankan *Big Cap*.

2.3 Kerangka/Skema Berpikir

Kerangka berpikir dalam penelitian ini dibangun berdasarkan sintesis antara teori pasar modal, *Behavioral Finance*, dan teknologi *Deep Learning*. Secara fundamental, penelitian ini beranjak dari premis bahwa pergerakan harga saham tidak hanya dipengaruhi oleh data historis masa lalu (*Technical Analysis*), tetapi juga oleh sentimen informasi yang beredar di publik (*Sentiment Analysis*).

Alur pikir penelitian dimulai dengan identifikasi masalah volatilitas harga saham perbankan *Big Cap* (BBCA dan BBRI) yang sering kali dipengaruhi oleh sentimen berita eksternal. Untuk menyelesaikan masalah prediksi yang akurat, digunakan pendekatan *Hybrid* yang menggabungkan dua aliran data yang berbeda. Proses penelitian dibagi menjadi tiga tahapan utama:

2.3.1 Tahap Input & Pra-pemrosesan (*Preprocessing*).

Data harga saham (OHLCV) yang bersifat numerik akan dinormalisasi menggunakan *MinMax Scaler*. Sementara itu, data berita keuangan yang bersifat tekstual tidak terstruktur akan melalui proses *Text Mining* yang ketat. Proses ini

melibatkan pembersihan data (*cleaning*), pengubahan kata ke bentuk dasar (*stemming*) menggunakan pustaka Sastrawi, dan pembobotan nilai sentimen menggunakan kamus InSet Lexicon. Penggunaan InSet dan Sastrawi dipilih untuk mengatasi kompleksitas Bahasa Indonesia yang tidak dapat ditangani dengan baik oleh kamus sentimen berbahasa Inggris.

2.3.2 Tahap Pengembangan Model *Hybrid*.


Skor sentimen harian yang dihasilkan kemudian digabungkan (*merged*) dengan data harga saham harian. Dataset gabungan (multivariat) ini menjadi input bagi algoritma *Long Short-Term Memory* (LSTM). LSTM dipilih karena arsitekturnya yang memiliki *memory cell* dan *gating mechanism* mampu mempelajari pola jangka panjang dan mencegah hilangnya informasi penting (*vanishing gradient*) dari rentetan data waktu (*time-series*).

2.3.3 Tahap Output & Evaluasi.

Model yang telah dilatih (*trained model*) diimplementasikan dan di-*deploy* ke dalam sebuah aplikasi web menggunakan framework Flask. Flask bertindak sebagai jembatan *backend* yang melayani permintaan pengguna untuk menghasilkan keluaran prediksi harga saham penutupan (*Predicted Close Price*) pada antarmuka web.

Kinerja model dievaluasi secara matematis menggunakan Root Mean Square Error (RMSE), Mean Absolute Error (MAE), dan Mean Absolute Percentage Error (MAPE). Evaluasi ini digunakan untuk membandingkan tingkat kesalahan prediksi antara Model Baseline LSTM yang hanya menggunakan data OHLCV dan Model Hybrid LSTM yang menggabungkan data OHLCV dengan skor sentimen berita. (Joddy, 2025; Saputra & Koesrindartoto, 2024).

Secara skematis, alur kerangka berpikir penelitian ini digambarkan sebagai berikut:



Gambar 2.1 Kerangka Berfikir

Penjelasan Detail Tahapan dalam Skema:

2.3.4 Pengumpulan Data.

Tahap ini merupakan fondasi penelitian di mana dua jenis data dikumpulkan secara paralel. Data kuantitatif berupa harga saham historis (*Open, High, Low, Close, Volume*) untuk emiten BBKA dan BBRI diambil menggunakan API *Yahoo Finance*. Secara bersamaan, data kualitatif berupa berita keuangan dikumpulkan melalui teknik *Web Scraping* dari portal berita nasional terpercaya (seperti Kontan dan CNBC Indonesia) untuk menangkap sentimen pasar yang relevan dengan periode penelitian.

2.3.5 Sastrawi Stemmer.

Sebelum analisis sentimen dilakukan, teks berita yang tidak terstruktur harus dibersihkan. Pustaka Sastrawi memegang peranan krusial dalam tahap ini, khususnya proses *stemming*. Sastrawi berfungsi mengubah kata-kata berimbuhan yang kompleks dalam bahasa Indonesia (misalnya: "mengkhawatirkan" atau "penurunan") menjadi kata dasarnya ("khawatir" atau "turun"). Proses ini vital agar kata-kata dalam berita dapat dicocokkan secara akurat dengan entri kata dasar yang terdapat dalam kamus sentimen.

2.3.6 InSet Lexicon.

Setelah teks dibersihkan, tahap selanjutnya adalah pembobotan sentimen menggunakan InSet (*Indonesian Sentiment Lexicon*). Berbeda dengan metode klasifikasi biner (hanya positif/negatif), InSet memberikan bobot skor numerik (misalnya rentang -5 hingga +5) untuk setiap kata yang terdeteksi. Akumulasi skor ini akan menghasilkan variabel "Skor Sentimen Harian" yang merepresentasikan

psikologi pasar—apakah pasar sedang optimis (*bullish*) atau pesimis (*bearish*)—yang kemudian siap dijadikan input numerik bagi model.

2.3.7 Fitur Fusi (*Fusion*).

Ini adalah tahap inti dari metode *Hybrid*. Data harga saham historis dan Skor Sentimen Harian yang memiliki skala berbeda akan dinormalisasi terlebih dahulu (menggunakan *MinMax Scaler*) agar berada dalam rentang nilai yang sama (0 hingga 1). Setelah dinormalisasi, kedua data ini digabungkan (*merged*) menjadi satu dataset multivariat. Fusi ini bertujuan agar model tidak hanya belajar dari pola angka masa lalu, tetapi juga memahami konteks "mengapa" harga bergerak berdasarkan sinyal dari berita.

2.3.8 LSTM Processing.

Dataset gabungan tersebut kemudian diproses oleh algoritma *Long Short-Term Memory* (LSTM). Sebagai komponen utama pemodelan, LSTM memanfaatkan mekanisme gerbang (*forget, input, output gates*) untuk mempelajari korelasi non-linear dan ketergantungan jangka panjang (*long-term dependencies*). Model akan dilatih untuk mengenali pola kompleks, misalnya bagaimana sentimen negatif yang muncul hari ini dapat memengaruhi volatilitas atau penurunan harga penutupan (*Close Price*) pada keesokan harinya.

2.3.9 Validasi Model.

Tahap validasi model dilakukan dengan membandingkan hasil prediksi harga penutupan saham dengan data harga aktual pada periode pengujian. Tingkat kesalahan prediksi diukur menggunakan Root Mean Square Error (RMSE), Mean Absolute Error (MAE), dan Mean Absolute Percentage Error (MAPE). RMSE digunakan untuk melihat besarnya kesalahan prediksi dengan penalti lebih besar

terhadap error yang tinggi, MAE digunakan untuk melihat rata-rata selisih absolut antara nilai aktual dan prediksi, sedangkan MAPE digunakan untuk melihat kesalahan prediksi dalam bentuk persentase. Evaluasi ini bertujuan untuk mengetahui apakah penambahan fitur sentimen berita pada Model Hybrid LSTM dapat menurunkan tingkat kesalahan prediksi dibandingkan Model Baseline LSTM.

BAB 3

ANALISIS DAN PERANCANGAN

3.1 Rekayasa Kebutuhan (*Requirements Engineering*)

Rekayasa kebutuhan merupakan tahapan awal dalam perancangan perangkat lunak yang bertujuan untuk memahami, mengidentifikasi, dan mendokumentasikan apa saja yang harus dapat dilakukan oleh sistem prediksi harga saham yang akan dibangun. Kebutuhan sistem ini diklasifikasikan ke dalam kebutuhan fungsional, kebutuhan non-fungsional, serta kebutuhan lingkungan sistem.

3.1.1 Kebutuhan Fungsional (*Functional Requirements*)

Kebutuhan fungsional mendefinisikan interaksi antara pengguna dan sistem, serta proses komputasi spesifik yang harus mampu dieksekusi oleh sistem di belakang layar (*backend*). Pada penelitian ini, sistem prediksi saham *Hybrid* memiliki kebutuhan fungsional sebagai berikut:

1. Sistem harus mampu melakukan ekstraksi data harga saham historis (BBCA dan BBRI) secara otomatis memanfaatkan API dari Yahoo Finance.
2. Sistem harus mampu melakukan *web scraping* atau ekstraksi data berita keuangan berbasis teks dari portal berita secara otomatis sesuai rentang waktu yang ditentukan.
3. Sistem harus mampu melakukan pra-pemrosesan teks (*text preprocessing*), yang meliputi pembersihan teks dan pemotongan kata berimbuhan (*stemming*) menggunakan pustaka Sastrawi.

4. Sistem harus mampu melakukan perhitungan skor sentimen menggunakan pendekatan leksikon (*InSet Lexicon*) terhadap teks berita yang telah dibersihkan.
5. Sistem harus mampu melakukan penyatuan data (*data fusion*), yakni menggabungkan data deret waktu harga saham dengan data skor sentimen ke dalam satu *dataset* multivariat.
6. Sistem harus mampu melatih model (*model training*) menggunakan algoritma *Long Short-Term Memory* (LSTM) berdasarkan *dataset* multivariat tersebut.
7. Sistem harus dapat melakukan perhitungan dan menampilkan hasil prediksi harga saham kepada pengguna.
8. Sistem harus menyediakan antarmuka web (dibangun menggunakan Flask) yang memungkinkan pengguna untuk memilih emiten saham dan melihat *output* berupa prediksi harga penutupan (*Close Price*) keesokan harinya beserta visualisasi grafiknya.

3.1.2 Kebutuhan Non-Fungsional (*Non-Functional Requirements*)

Kebutuhan non-fungsional mendefinisikan batasan, kualitas, dan kriteria performa dari sistem yang dibangun. Kebutuhan non-fungsional pada sistem ini meliputi:

1. Ketersediaan dan Portabilitas (*Availability & Portability*): Sistem dirancang berbasis web yang dapat dijalankan secara lokal (*localhost*) melalui peramban web (*web browser*) standar seperti Google Chrome atau Mozilla Firefox, tanpa memerlukan instalasi perangkat lunak tambahan di sisi pengguna akhir.

2. Waktu Respons (*Response Time*): Sistem diharapkan mampu melakukan komputasi prediksi data baru dan menampilkan hasilnya pada antarmuka web dalam waktu kurang dari 60 detik setelah pengguna menekan tombol eksekusi.
3. Kinerja model prediksi pada sistem harus divalidasi menggunakan Root Mean Square Error (RMSE), Mean Absolute Error (MAE), dan Mean Absolute Percentage Error (MAPE), kemudian dibandingkan antara Model Baseline LSTM dan Model Hybrid LSTM.

3.1.3 Kebutuhan Lingkungan Sistem (Perangkat Keras dan Lunak)

Untuk mendukung kelancaran pembangunan dan pengoperasian sistem komputasi ini, diperlukan spesifikasi lingkungan sistem yang memadai dari sisi perangkat keras maupun perangkat lunak, yaitu:

1. Perangkat Keras (*Hardware*): Sistem membutuhkan prosesor komputasi minimal setara Intel Core i5 atau AMD Ryzen 5, kapasitas memori utama (RAM) minimal 8 Gigabyte untuk mengoptimalkan proses pelatihan algoritma LSTM, serta media penyimpanan berbasis *Solid State Drive* (SSD) dengan ruang kosong minimal 20 Gigabyte.
2. Perangkat Lunak (*Software*): Sistem dikembangkan berlandaskan bahasa pemrograman Python versi 3.10 dan dioperasikan pada sistem operasi Windows 10/11 64-bit. Proses penulisan kode dieksekusi menggunakan lingkungan pengembangan *Visual Studio Code*. Kinerja sistem ditunjang oleh serangkaian pustaka utama, yang meliputi TensorFlow dan Keras untuk pembangunan arsitektur *Deep Learning*, Pandas dan NumPy untuk manipulasi himpunan data, Sastrawi untuk pemrosesan teks, Yfinance untuk

akuisisi data bursa, Scikit-Learn untuk standardisasi data, serta Flask untuk merancang kerangka kerja antarmuka web.

Pustaka (*Libraries*) Utama: TensorFlow/Keras (untuk pemodelan LSTM), Pandas dan NumPy (untuk manipulasi *dataset*), Sastrawi (untuk *stemming* teks), yfinance (untuk data saham), Scikit-Learn (untuk normalisasi dan evaluasi), serta Flask (untuk *routing* web dan pembuatan API).

3.2 Pemilihan Metode, Teknik, dan Kerangka Kerja

Tahap ini menguraikan dasar pertimbangan akademis dan justifikasi teknis di balik pemilihan metode komputasi serta kerangka kerja operasional yang diterapkan dalam proses perekayasaan sistem prediksi. Pemilihan ini didasarkan pada kesesuaian teknologi dengan karakteristik himpunan data dan tujuan akhir penelitian.

3.2.1 Metodologi Pengembangan

Pemilihan metodologi pengembangan sistem pada penelitian ini menggunakan kerangka kerja Machine Learning Development Life Cycle (MLDLC). Pendekatan ini dipilih karena MLDLC merupakan metodologi modern yang dirancang secara spesifik untuk mengakomodasi kompleksitas proyek kecerdasan buatan (Artificial Intelligence) dan Deep Learning. Penggunaan MLDLC memastikan bahwa alur pengembangan model prediktif berjalan secara sistematis, berfokus pada optimasi algoritma, dan dapat diimplementasikan sebagai perangkat lunak yang fungsional.

Siklus hidup MLDLC pada penelitian ini diterapkan melalui tujuh tahapan utama yang berkesinambungan:

1. Pengumpulan Data (Data Gathering): Fase ekstraksi data mentah, mencakup penarikan data historis saham via API Yahoo Finance dan data teks berita dari portal nasional.
2. Persiapan Data (Data Preparation): Fase pembersihan awal, meliputi penghapusan karakter tidak relevan pada teks (cleaning) dan pembersihan nilai kosong pada data saham.
3. Transformasi Data (Data Wrangling): Fase konversi format data, mencakup pemotongan kata berimbuhan (stemming) dengan Sastrawi, pembobotan sentimen dengan InSet Lexicon, serta normalisasi harga menggunakan MinMax Scaler.
4. Analisis Data (Data Analysis): Fase eksplorasi dan penyatuan data (Data Fusion) untuk menggabungkan skor sentimen harian dengan matriks harga saham.
5. Pelatihan Model (Model Training): Fase perancangan dan pelatihan algoritma Long Short-Term Memory (LSTM) untuk membangun Model Baseline dan Model Hybrid.
6. Pengujian Model (Model Testing): Fase evaluasi tingkat kesalahan prediksi model menggunakan metrik RMSE, MAE, dan MAPE pada data uji.
7. Penyebaran Model (Deployment): Fase implementasi model terlatih ke dalam antarmuka aplikasi web berbasis Flask (Sentilytics)..

3.2.2 Pemilihan Teknik Pemodelan


Penelitian ini mengadopsi pendekatan pemodelan hibrida yang mengintegrasikan algoritma *Deep Learning* dengan teknik Pemrosesan Bahasa Alami (*Natural Language Processing*). Algoritma *Long Short-Term Memory* (LSTM) dipilih sebagai fondasi prediksi utama karena kemampuannya yang terbukti superior dalam memproses data deret waktu (*time-series*) yang fluktuatif seperti harga saham. Kehadiran mekanisme gerbang memori (*memory gates*) pada LSTM mampu mengatasi masalah gradien menghilang (*vanishing gradient*) yang sering terjadi pada jaringan saraf tiruan tradisional. Sebagai fitur tambahan pendukung LSTM, teknik analisis sentimen berbasis leksikon dipilih melalui kolaborasi pustaka Sastrawi dan kamus InSet. Pendekatan berbasis leksikon ini dinilai paling efisien untuk memproses morfologi tata bahasa Indonesia secara komputasional, karena mampu menghasilkan bobot sentimen yang akurat tanpa memerlukan sumber daya komputasi masif untuk melatih model bahasa besar dari awal.

3.2.3 Pemilihan Kerangka Kerja Implementasi

Untuk menjembatani hasil pemodelan kecerdasan buatan dengan interaksi pengguna, penelitian ini menetapkan Flask sebagai kerangka kerja aplikasi web utama. Flask dipilih karena posisinya sebagai kerangka kerja mikro (*micro-framework*) yang dibangun secara natif menggunakan bahasa pemrograman Python. Karakteristiknya yang ringan dan modular sangat kompatibel untuk digabungkan dengan pustaka pemrosesan data bervolume tinggi seperti TensorFlow dan Pandas. Dalam arsitektur sistem ini, Flask berperan krusial sebagai antarmuka pemrograman aplikasi (*Backend API*) yang bertugas menerima perintah

dari pengguna, memicu proses komputasi prediksi pada model LSTM, dan mengembalikan hasil visualisasinya secara interaktif ke layar peramban.

3.3 Perancangan Proses



Gambar 3.1 Flowchart Sistem Sentilytics

Perancangan proses memetakan alur kerja komputasional sistem dari tahap penerimaan data mentah hingga menghasilkan keluaran berupa nilai prediksi harga saham. Alur proses ini dirancang secara sekuensial agar setiap modul dapat beroperasi secara sinkron dalam menghasilkan himpunan data multivariat yang valid untuk dilatih oleh algoritma kecerdasan buatan. Rangkaian perancangan proses ini diuraikan ke dalam tujuh tahapan komputasional yang dipetakan agar selaras dengan fase-fase dalam metodologi MLDLC, yaitu sebagai berikut:

3.3.1 Proses Pengumpulan Data (Data Gathering)

Sistem menginisiasi penarikan data secara paralel dari dua sumber yang berbeda. Sumber pertama adalah data harga saham harian berformat numerik untuk emiten BBKA dan BBRI yang diekstraksi melalui antarmuka pemrograman aplikasi Yahoo Finance. Sumber kedua adalah data teks berita kualitatif yang dikumpulkan dari portal berita keuangan nasional menggunakan protokol Really Simple Syndication (RSS) Feed sesuai dengan rentang waktu pengamatan yang telah ditetapkan.

3.3.2 Proses Persiapan Data (Data Preparation)

Tahap ini berfokus pada pembersihan data mentah. Teks judul berita yang telah dikumpulkan dibersihkan dari berbagai karakter yang tidak relevan (cleaning), diseragamkan menjadi huruf kecil (case folding), dan dihilangkan kata hubung yang tidak memiliki makna sentimen (stopword removal). Sementara itu, data saham dibersihkan dari anomali atau data yang kosong (missing values).

3.3.3 Proses Transformasi Data (Data Wrangling)

Data yang telah bersih dikonversi ke dalam format komputasional. Pada data teks, dilakukan reduksi morfologis atau stemming menggunakan pustaka Sastrawi untuk memotong imbuhan menjadi kata dasar. Teks tersebut kemudian dikuantifikasi menggunakan kamus leksikon InSet untuk menghasilkan skor sentimen. Pada data deret waktu saham, diterapkan metode MinMax Scaler untuk menormalisasi seluruh rentang nilai ke dalam skala nol hingga satu guna mempercepat konvergensi algoritma.

3.3.4 Proses Analisis Data (Data Analysis)

Skor sentimen harian yang merepresentasikan kondisi psikologis pasar digabungkan secara selaras (Data Fusion) dengan himpunan data harga saham berdasarkan kecocokan atribut tanggal transaksi. Sistem juga diprogram untuk menangani keberadaan hari bursa yang tidak memiliki rilis berita dengan cara mengimputasi nilai nol, yang merepresentasikan kondisi sentimen pasar yang netral.

3.3.5 Proses Pelatihan Model (Model Training)

Himpunan data multivariat yang telah tergabung secara utuh dibagi menjadi dua partisi utama, yaitu data latih sebesar delapan puluh persen dan data uji sebesar dua puluh persen. Data latih kemudian diumpankan ke dalam arsitektur hibrida LSTM untuk melatih parameter dan bobot jaringan saraf tiruan. Sistem membangun dua skenario pemodelan: Model Baseline LSTM (hanya menggunakan fitur OHLCV) dan Model Hybrid LSTM (menggunakan fitur OHLCV dan skor sentimen).

3.3.6 Proses Pengujian Model (Model Testing)

Model yang telah dilatih kemudian diuji kinerjanya menggunakan bagian data uji (test set). Tingkat akurasi dan kesalahan prediksi harga penutupan dievaluasi secara matematis untuk membandingkan kinerja antara Model Baseline dan Model Hybrid.

3.3.7 Proses Penyebaran Model (Deployment)

Sebagai langkah akhir, model yang telah divalidasi disimpan dalam format .keras beserta berkas scaler pembantunya. Model prediktif ini diintegrasikan ke

dalam lingkungan backend Flask, sehingga dapat melayani interaksi dari pengguna melalui antarmuka web Sentilytics.

Pada tahap pemodelan, penelitian ini membangun dua skenario model, yaitu Model Baseline LSTM dan Model Hybrid LSTM. Model Baseline LSTM menggunakan fitur Open, High, Low, Close, dan Volume (OHLCV) sebagai input. Model Hybrid LSTM menggunakan fitur Open, High, Low, Close, Volume, serta skor sentimen berita sebagai input tambahan. Perbandingan kedua model dilakukan untuk mengetahui apakah penambahan fitur sentimen berita dapat menurunkan tingkat kesalahan prediksi harga penutupan saham.

Dataset diubah menjadi bentuk sequence agar dapat diproses oleh LSTM. Pada rancangan awal, window size yang digunakan adalah 30 hari perdagangan. Artinya, data 30 hari perdagangan sebelumnya digunakan sebagai input untuk memprediksi harga penutupan pada hari perdagangan berikutnya atau Close Price $H+1$. Pembagian data dilakukan berdasarkan urutan waktu, yaitu 80% data awal sebagai data latih dan 20% data akhir sebagai data uji.

Tabel 3.1 Rancangan Hyperparameter Awal Model LSTM

Parameter	Nilai Awal
<i>Window size</i>	30 hari perdagangan
<i>LSTM units</i>	64
<i>Dropout</i>	0.2
<i>Dense output</i>	1
<i>Optimizer</i>	Adam
<i>Loss function</i>	<i>Mean Squared Error</i>
<i>Epoch</i>	50
<i>Batch size</i>	32
<i>Train-test split</i>	80:20

3.4 Perancangan Sistem


Perancangan sistem menjelaskan arsitektur perangkat lunak secara menyeluruh yang dibangun agar model prediksi komputasional dapat dioperasikan secara interaktif oleh pengguna akhir. Sistem Flask dirancang sebagai media visualisasi hasil prediksi dan evaluasi model. Aplikasi ini memiliki dua mode utama, yaitu Mode Evaluasi Model dan Mode Simulasi Forecast. Mode Evaluasi Model digunakan untuk menampilkan grafik harga aktual dibandingkan harga prediksi serta nilai RMSE, MAE, dan MAPE pada data uji historis. Mode Simulasi Forecast digunakan untuk menampilkan prediksi harga penutupan saham sampai H+7 sebagai fitur visualisasi tambahan. Evaluasi utama penelitian tetap dilakukan pada prediksi H+1 karena nilai aktualnya tersedia pada data uji. Arsitektur sistem ini mengadopsi pola klien-server terpadu yang beroperasi di dalam lingkungan komputasi lokal. Rancangan arsitektur perangkat lunak ini terbagi ke dalam tiga modul operasional utama sebagai berikut:

3.4.1 Pemodelan Interaksi Pengguna (*Use Case Diagram*)

Perancangan fungsionalitas sistem yang menggambarkan interaksi antara pengguna dan perangkat lunak dimodelkan menggunakan *Unified Modeling Language* (UML) berupa *Use Case Diagram*. Dalam pemodelan sistem Sentilytics ini, terdapat dua peran aktor pengguna, yaitu pengguna biasa (*user*) dan administrator (*admin*).

Pengguna biasa memiliki hak akses untuk mengeksekusi fungsi-fungsi utama, di antaranya: melakukan proses autentikasi (registrasi dan *login*), melihat *dashboard* utama, melihat komparasi evaluasi model, melihat simulasi *forecast* H+7, melihat *dataset summary*, dan melakukan *logout*. Sementara itu, administrator memiliki satu hak akses tambahan khusus untuk membuka halaman *admin panel*.

Terdapat pembatasan akses (otorisasi) yang diterapkan secara ketat agar halaman *admin panel* beserta fungsi pengelolaannya tidak dapat diakses oleh pengguna biasa. Diagram ini menegaskan bahwa aplikasi web Flask yang dibangun bersifat mandiri dan berfokus pada penyajian informasi visualisasi prediksi dengan pemisahan wewenang yang jelas. Pemodelan interaksi kedua aktor terhadap sistem tersebut dapat dilihat pada Gambar 3.2 berikut:



Gambar 3.2 Use Case Diagram Sistem Sentilytics

3.4.2 Arsitektur Sistem Web Flask

Perancangan arsitektur sistem dimodelkan menggunakan diagram blok tingkat tinggi yang menggambarkan integrasi antara komponen *frontend*, *backend*, dan model kecerdasan buatan. Sistem ini mengadopsi pola *Client-Server* sederhana yang berjalan di lingkungan komputasi lokal. Di sisi *Client*, terdapat antarmuka web yang dibangun menggunakan markah HTML dan tata letak CSS untuk menerima masukan dari pengguna dan menampilkan hasil prediksi. Antarmuka ini berkomunikasi secara asinkron dengan sisi *Server (Backend)* yang dibangun menggunakan kerangka kerja Flask berbasis bahasa Python. Flask bertugas mengelola permintaan (*routing*), melakukan prapemrosesan himpunan data


numerik dan teks secara *real-time*, memanggil model LSTM yang tersimpan dalam format statis, dan mengirimkan kembali hasil komputasi serta visualisasi grafik ke sisi *Client* untuk dirender di layar peramban.

3.4.3 Rancangan Antarmuka Pengguna (*Wireframe*)

Perancangan antarmuka pengguna dimodelkan menggunakan *wireframe* atau kerangka layar tingkat rendah untuk memberikan gambaran tata letak (*layout*) aplikasi web Flask yang akan dibangun. Rancangan antarmuka ini dirancang secara modular untuk mengakomodasi berbagai fungsi sistem, yang direpresentasikan ke dalam enam halaman operasional utama berikut:

1. Perancangan Halaman Login

Merupakan halaman autentikasi awal yang harus dilewati oleh pengguna sebelum dapat mengakses *dashboard* utama. Halaman ini memuat antarmuka formulir masukan untuk memvalidasi kredensial pengguna, yang terdiri dari kolom alamat surat elektronik (*email*) dan kata sandi (*password*), serta dilengkapi dengan tautan navigasi menuju halaman pendaftaran akun baru (*register*).



Gambar 3.3 Wireframe Login Page

2. Perancangan Halaman Dashboard Utama

Merupakan halaman inti yang dibagi menjadi dua panel fungsional. Panel sisi kiri berfungsi sebagai area masukan pengguna untuk memilih emiten saham dan jenis model prediksinya. Panel kanvas utama di sisi kanan berfungsi sebagai area keluaran yang merender grafik pergerakan harga aktual berbanding harga prediksi secara dinamis, dilengkapi dengan panel informasi terpisah yang menyajikan nilai prediksi numerik serta metrik evaluasi (RMSE, MAE, dan MAPE).



Gambar 3.4 Wireframe Dashboard Utama

3. Perancangan Halaman Admin Panel

Merupakan halaman khusus pengelola sistem (*administrator*) yang berfungsi untuk memonitor ringkasan total pengguna terdaftar, status ketersediaan himpunan data, serta status berkas model *.keras* dan *scaler* yang siap digunakan.



Gambar 3.5 Wireframe Admin Panel

4. Perancangan Halaman Model Evaluation

Halaman operasional yang difokuskan untuk menyajikan komparasi akurasi tingkat kesalahan prediksi. Visualisasi pada halaman ini membandingkan kinerja metrik Model *Baseline* LSTM dan Model *Hybrid* LSTM secara berdampingan melalui bentuk tabel dan grafik batang interaktif.



Gambar 3.6 Wireframe Model Evaluation

5. Perancangan Halaman Forecast Simulation H+7

Halaman yang secara khusus dirancang untuk menampilkan tabel simulasi proyeksi harga penutupan saham hingga tujuh langkah (hari perdagangan) ke depan, beserta grafik garis tren masa depannya.



Gambar 3.7 Wireframe Forecast Simulation H+7

6. Perancangan Halaman Dataset Summary

Halaman yang menyediakan transparansi data kepada pengguna. Halaman ini menampilkan rincian dimensi matriks himpunan data historis, total artikel berita yang berhasil diekstraksi, status proses pemberian skor sentimen, dan diagram lingkaran yang memvisualisasikan persentase distribusi sentimen pasar.



Gambar 3.8 Wireframe Dataset Summary

3.5 Perancangan Pengujian

Perancangan pengujian disusun untuk memvalidasi secara empiris apakah sistem perangkat lunak dan model prediktif yang dibangun telah memenuhi spesifikasi rekayasa kebutuhan serta mampu menjawab rumusan masalah penelitian. Pengujian sistem ini diklasifikasikan ke dalam dua pendekatan evaluasi utama, yaitu pengujian komputasional dan pengujian fungsionalitas.

3.5.1 Pengujian Algoritma Pemodelan

Pengujian algoritma pemodelan dilakukan untuk mengevaluasi kinerja prediksi dari Model Baseline LSTM dan Model Hybrid LSTM. Model Baseline LSTM menggunakan fitur harga historis OHLCV, sedangkan Model Hybrid LSTM menggunakan fitur OHLCV yang digabungkan dengan skor sentimen berita. Hasil prediksi kedua model dibandingkan dengan harga aktual pada data uji. Evaluasi dilakukan menggunakan tiga metrik, yaitu Root Mean Square Error (RMSE), Mean Absolute Error (MAE), dan Mean Absolute Percentage Error (MAPE). Model

dengan nilai RMSE, MAE, dan MAPE yang lebih rendah menunjukkan tingkat kesalahan prediksi yang lebih kecil.

3.5.2 Pengujian Fungsionalitas Sistem

Pengujian lapis kedua ini menggunakan metode pengujian kotak hitam (*Black-Box Testing*) yang berfokus murni pada kesesuaian spesifikasi operasional perangkat lunak antarmuka web Flask tanpa meninjau struktur kode logis di baliknya. Skenario pengujian kotak hitam ini mencakup tiga pengujian utama. Pengujian pertama adalah skenario validasi masukan data untuk memastikan sistem mampu memproses parameter emiten yang dipilih pengguna serta menolak interaksi yang tidak sah dengan menampilkan pesan galat yang sesuai. Pengujian kedua adalah skenario uji integrasi kerangka kerja untuk memastikan peladen Flask berhasil menjembatani pengiriman komputasi dari antarmuka HTML ke model LSTM tanpa mengalami kelebihan beban waktu respons (*time-out*). Pengujian ketiga adalah skenario uji ketepatan visualisasi untuk memverifikasi keberhasilan sistem dalam merender teks hasil prediksi penutupan harga serta menampilkan grafik perbandingan harga secara presisi pada layar peramban web pengguna.

BAB 4

IMPLEMENTASI DAN PENGUJIAN

4.1 Implementasi

Tahap implementasi merupakan tahapan penerapan rancangan sistem yang telah dijelaskan pada Bab 3 ke dalam bentuk program yang dapat dijalankan. Implementasi dilakukan dengan merealisasikan tujuh tahapan Machine Learning Development Life Cycle (MLDLC), mulai dari pengumpulan data (data gathering), persiapan data (data preparation), transformasi data (data wrangling), analisis data (data analysis), pelatihan model (model training), pengujian model (model testing), hingga penyebaran model (deployment) ke dalam aplikasi web berbasis Flask.

Implementasi pada penelitian ini berfokus pada dua aspek utama, yaitu implementasi model prediksi berbasis Artificial Intelligence dan implementasi prototipe aplikasi web sebagai media visualisasi hasil. Model prediksi yang dibangun terdiri dari Model Baseline LSTM dan Model Hybrid LSTM. Model Baseline LSTM menggunakan fitur harga saham historis berupa Open, High, Low, Close, dan Volume (OHLCV), sedangkan Model Hybrid LSTM menggunakan fitur OHLCV yang digabungkan dengan skor sentimen berita. Hal ini sesuai dengan tujuan penelitian yang membandingkan kinerja Model Baseline LSTM dan Model Hybrid LSTM berdasarkan metrik RMSE, MAE, dan MAPE.

Selain model prediksi, penelitian ini juga mengimplementasikan aplikasi web Sentilytics menggunakan framework Flask. Aplikasi web ini digunakan untuk menampilkan hasil evaluasi model, grafik harga aktual dibandingkan harga prediksi, simulasi forecast sampai tujuh hari perdagangan ke depan, ringkasan dataset, serta halaman admin. Aplikasi ini tidak dimaksudkan sebagai rekomendasi

investasi, melainkan sebagai prototipe visualisasi hasil model prediksi berbasis Artificial Intelligence.

4.1.1 Lingkungan Implementasi

Implementasi sistem dilakukan pada lingkungan komputasi lokal. Lingkungan ini digunakan untuk menjalankan seluruh proses pengembangan, mulai dari pengumpulan data, pra-pemrosesan, pelatihan model, evaluasi, hingga pengujian aplikasi web. Pemilihan lingkungan lokal dilakukan agar proses pengembangan dapat dikontrol secara langsung dan seluruh tahapan implementasi dapat diuji sebelum sistem digunakan untuk demonstrasi.

Spesifikasi perangkat keras yang digunakan dalam implementasi sistem ditunjukkan pada Tabel 4.1.

Tabel 4.1 Spesifikasi Perangkat Keras

Komponen	Spesifikasi
Prosesor	Intel Core i5 / AMD Ryzen 5 atau setara
Memori	16 GB RAM
Penyimpanan	SSD / HDD dengan ruang kosong minimal 20 GB
Perangkat	Laptop / komputer pribadi
Sistem Operasi	Windows 10 / Windows 11 64-bit

Perangkat lunak dan pustaka yang digunakan dalam implementasi sistem ditunjukkan pada Tabel 4.2.

Tabel 4.2 Spesifikasi Perangkat Lunak

Perangkat Lunak / Pustaka	Fungsi
Python 3.10.11	Bahasa pemrograman utama
TensorFlow / Keras	Implementasi model LSTM
Pandas	Pengolahan dan manipulasi dataset
NumPy	Operasi numerik
Scikit-learn	Normalisasi data dan perhitungan metrik evaluasi
yfinance	Pengambilan data historis saham
BeautifulSoup / Feedparser	Pengambilan dan pembacaan data berita
Sastrawi	Stemming teks Bahasa Indonesia
InSet Lexicon	Perhitungan skor sentimen berbasis leksikon
Flask	Pengembangan aplikasi web

Perangkat Lunak / Pustaka	Fungsi
Chart.js	Visualisasi grafik pada dashboard
SQLite	Penyimpanan data pengguna dan autentikasi
Pytest	Pengujian unit pada modul program

Penggunaan Python sebagai bahasa pemrograman utama disesuaikan dengan kebutuhan implementasi model Artificial Intelligence dan pengolahan data. Pada Bab 2, Python telah dijelaskan sebagai bahasa yang umum digunakan dalam pengembangan kecerdasan buatan dan data science karena memiliki pustaka yang mendukung pemrosesan data serta pembangunan model machine learning.

4.1.2 Implementasi Pengumpulan dan Pra-pemrosesan Data

Tahap pengumpulan data dilakukan terhadap dua jenis data, yaitu data historis harga saham dan data berita keuangan. Data harga saham digunakan sebagai data numerik deret waktu, sedangkan data berita digunakan sebagai sumber informasi tekstual untuk menghasilkan skor sentimen.

Data harga saham yang digunakan dalam penelitian ini adalah data harian saham BBKA dan BBRI pada periode 1 Januari 2023 sampai 31 Desember 2024. Data harga saham terdiri dari atribut Open, High, Low, Close, dan Volume. Atribut Close digunakan sebagai dasar pembentukan target prediksi harga penutupan pada hari perdagangan berikutnya atau Close Price H+1. Penggunaan data OHLCV, periode penelitian, serta objek BBKA dan BBRI telah ditetapkan pada batasan masalah penelitian.

Data berita keuangan dikumpulkan dari portal berita CNBC Indonesia dan Kontan. Teks berita yang digunakan dalam proses analisis sentimen terdiri dari judul berita dan ringkasan berita apabila tersedia. Apabila ringkasan tidak tersedia, sistem menggunakan judul berita sebagai sumber teks sentimen. Hasil

pengumpulan berita pada implementasi sistem menghasilkan 1.305 data berita dengan rincian yang ditunjukkan pada Tabel 4.3.

Tabel 4.3 Jumlah Data Berita Berdasarkan Sumber dan Emiten

Sumber Berita	BBCA	BBRI	Total
CNBC Indonesia	746	108	854
Kontan	301	150	451
Total	1.047	258	1.305

Berdasarkan Tabel 4.3, jumlah berita yang berhasil dikumpulkan untuk BBCA lebih banyak dibandingkan BBRI. Perbedaan jumlah berita tersebut terjadi karena intensitas pemberitaan pada masing-masing emiten tidak selalu sama pada periode pengamatan. Data berita yang telah terkumpul kemudian digunakan pada proses pra-pemrosesan teks sebelum dilakukan perhitungan skor sentimen.

Pra-pemrosesan data harga saham dilakukan dengan membersihkan data kosong, mengurutkan data berdasarkan tanggal, dan melakukan transformasi skala menggunakan MinMax Scaler. Normalisasi dilakukan agar setiap fitur numerik berada pada rentang nilai yang seragam sehingga dapat diproses oleh model LSTM. Pembagian data dilakukan berdasarkan urutan waktu untuk menjaga karakteristik data deret waktu dan menghindari data leakage.

Sementara itu, pra-pemrosesan teks berita dilakukan melalui beberapa tahapan, yaitu case folding, cleaning, stopword removal, tokenisasi, dan stemming menggunakan pustaka Sastrawi. Proses ini dilakukan agar teks berita menjadi lebih bersih dan dapat dicocokkan dengan daftar kata pada InSet Lexicon. Tahapan pra-pemrosesan teks dengan Sastrawi dan InSet juga telah dijelaskan pada Bab 2 sebagai bagian dari proses analisis sentimen Bahasa Indonesia.

Contoh hasil pra-pemrosesan teks ditunjukkan pada Tabel 4.4.

Tabel 4.4 Contoh Pra-pemrosesan Teks Berita

Tahap	Hasil
Teks awal	Ada Salim & Tangan Dingin Mochtar Riady Di balik Kerajaan BCA
Case folding	ada salim & tangan dingin mochtar riady di balik kerajaan bca
Cleaning	ada salim tangan dingin mochtar riady di balik kerajaan bca
Stopword removal	salim tangan dingin mochtar riady balik kerajaan bca
Stemming	salim tangan dingin mochtar riady balik raja bca

4.1.3 Implementasi Analisis Sentimen dan Data Fusion

Analisis sentimen dilakukan dengan pendekatan Lexicon-Based menggunakan InSet Lexicon. Setiap kata hasil pra-pemrosesan dicocokkan dengan daftar kata pada kamus InSet. Apabila kata ditemukan pada leksikon, sistem mengambil bobot sentimen dari kata tersebut. Skor sentimen berita dihitung berdasarkan rata-rata bobot kata sentimen yang ditemukan pada satu teks berita. Apabila tidak ditemukan kata yang sesuai dengan InSet Lexicon, skor sentimen berita diberi nilai 0 sebagai representasi netral.

Hasil perhitungan skor sentimen kemudian diagregasi menjadi skor sentimen harian berdasarkan tanggal dan emiten. Agregasi ini dilakukan karena data harga saham memiliki frekuensi harian, sehingga skor sentimen juga perlu disesuaikan ke format harian. Apabila terdapat lebih dari satu berita pada tanggal yang sama untuk emiten yang sama, sistem menghitung rata-rata skor sentimen pada tanggal tersebut. Jika pada suatu tanggal perdagangan tidak ditemukan berita yang relevan, nilai sentimen diisi dengan 0 yang merepresentasikan kondisi netral. Hasil implementasi sentimen harian ditunjukkan pada Tabel 4.5.

Tabel 4.5 Ringkasan Sentimen Harian

Emiten	Jumlah Tanggal Sentimen	Jumlah Sentimen Tidak Nol
BBCA	469	449
BBRI	178	168

Setelah skor sentimen harian diperoleh, tahap berikutnya adalah *data fusion*. *Data fusion* dilakukan dengan menggabungkan data harga saham dan skor sentimen harian berdasarkan atribut tanggal dan emiten. Proses ini menghasilkan dataset multivariat yang digunakan sebagai input pada Model Hybrid LSTM.

Dataset fusion yang dihasilkan pada implementasi sistem ditunjukkan pada Tabel 4.6.

Tabel 4.6 Ringkasan Dataset Fusion

Emiten	Jumlah Baris Dataset	Jumlah Sentiment Score Tidak Nol
BBCA	475	364
BBRI	475	148

Dataset fusion memiliki fitur Open, High, Low, Close, Volume, dan sentiment_score. Selain itu, dataset juga memiliki target Close_H+1 yang dibentuk dengan menggeser nilai Close satu hari perdagangan ke depan. Dengan demikian, input model berasal dari data historis, sedangkan target yang diprediksi adalah harga penutupan hari perdagangan berikutnya.

Contoh struktur dataset fusion ditunjukkan pada Tabel 4.7.

Tabel 4.7 Struktur Dataset Fusion

Emiten	Tanggal	Open	High	Low	Close	Volume	Sentiment Score	Target Close H+1
BBCA	04/01/23	7.470,45	7.514,26	7.317,10	7.317,10	90.918.800	1,50	7.229,47
BBRI	04/01/23	3.586,88	3.586,88	3.527,72	3.527,72	188.071.000	1,33	3.431,57

4.1.4 Implementasi Model Baseline LSTM dan Hybrid LSTM

Implementasi model prediksi dilakukan dengan membangun dua skenario model, yaitu Model Baseline LSTM dan Model Hybrid LSTM. Model Baseline LSTM digunakan sebagai pembandingan karena hanya menggunakan data harga

saham historis. Model Hybrid LSTM digunakan untuk menguji apakah penambahan skor sentimen berita dapat menurunkan tingkat kesalahan prediksi.

Model Baseline LSTM menggunakan lima fitur input, yaitu Open, High, Low, Close, dan Volume. Model Hybrid LSTM menggunakan enam fitur input, yaitu Open, High, Low, Close, Volume, dan sentiment_score. Target prediksi pada kedua model adalah Close_H1 atau harga penutupan saham pada hari perdagangan berikutnya. Perbedaan fitur input pada kedua model ditunjukkan pada Tabel 4.8.

Tabel 4.8 Perbandingan Fitur Input Model

Model	Fitur Input	Target
Baseline LSTM	Open, High, Low, Close, Volume	Close_H+1
Hybrid LSTM	Open, High, Low, Close, Volume, sentiment_score	Close_H+1

Sebelum data dimasukkan ke model LSTM, dataset diubah menjadi bentuk sequence dengan pendekatan lookback window. Dengan demikian, bentuk input model LSTM adalah tiga dimensi, yaitu jumlah sampel, jumlah timestep sebesar 30 hari, dan jumlah fitur. Model Baseline LSTM memiliki lima fitur input, sedangkan Model Hybrid LSTM memiliki enam fitur input. Bentuk input ini diperlukan karena LSTM memproses data dalam format sequence untuk mempelajari pola historis pada data deret waktu. Pada implementasi ini, window size yang digunakan adalah 30 hari perdagangan. Artinya, data 30 hari perdagangan sebelumnya digunakan sebagai input untuk memprediksi harga penutupan pada hari perdagangan berikutnya.

Konfigurasi parameter model yang digunakan ditunjukkan pada Tabel 4.9.

Tabel 4.9 Konfigurasi Parameter Model LSTM

Parameter	Nilai
Window size	30 hari perdagangan
LSTM units	64
Dropout	0,2

Parameter	Nilai
Dense output	1
Optimizer	Adam
Loss function	Mean Squared Error
Epoch	50
Batch size	32
Train-test split	80:20

Pembagian data dilakukan secara berurutan berdasarkan waktu, yaitu 80% data awal digunakan sebagai data latih dan 20% data akhir digunakan sebagai data uji. Pembagian ini dilakukan agar model tidak memperoleh informasi dari data masa depan saat proses pelatihan.

Model yang telah dilatih disimpan dalam format .keras agar dapat digunakan kembali pada proses evaluasi dan aplikasi web. Model Baseline LSTM dan Hybrid LSTM disimpan pada folder models, sedangkan scaler yang digunakan pada proses normalisasi disimpan dalam format .pkl. Penyimpanan model dan scaler dilakukan agar proses inverse transform dan inference pada dashboard dapat menggunakan konfigurasi transformasi data yang sama dengan tahap pelatihan.

4.1.5 Implementasi Dashboard Web Sentilytics

Implementasi aplikasi web dilakukan menggunakan framework Flask. Aplikasi web yang dikembangkan diberi nama Sentilytics dan berfungsi sebagai media visualisasi hasil model prediksi. Flask digunakan sebagai backend untuk menangani routing, autentikasi pengguna, pemanggilan data hasil evaluasi, pemanggilan file forecast, serta pengiriman data ke halaman frontend.

Pada sisi frontend, sistem menggunakan HTML, CSS, JavaScript, dan Chart.js untuk menampilkan grafik hasil prediksi. Grafik yang ditampilkan meliputi grafik perbandingan harga aktual dan harga prediksi serta grafik simulasi forecast

sampai H+7. Penggunaan Flask sebagai antarmuka web sesuai dengan rancangan Bab 3, yaitu aplikasi web digunakan untuk menampilkan hasil prediksi, grafik aktual dibandingkan prediksi, nilai evaluasi, dan simulasi forecast sampai tujuh hari perdagangan ke depan.


Fitur utama yang diimplementasikan pada aplikasi web Sentilytics ditunjukkan pada Tabel 4.10.

Tabel 4.10 Fitur Aplikasi Web Sentilytics

Fitur	Keterangan
Login	Digunakan untuk autentikasi pengguna sebelum masuk ke dashboard
Register	Digunakan untuk membuat akun pengguna baru
Dashboard utama	Menampilkan ringkasan sistem dan navigasi utama
Evaluasi model	Menampilkan grafik actual vs predicted dan nilai RMSE, MAE, MAPE
Forecast H+7	Menampilkan simulasi prediksi harga penutupan sampai tujuh hari perdagangan ke depan
Dataset summary	Menampilkan ringkasan dataset saham, berita, sentimen, dan data fusion
Admin panel	Menampilkan halaman khusus admin untuk pengelolaan sistem
Access denied	Menolak akses user biasa ke halaman admin
Disclaimer	Menampilkan keterangan bahwa sistem bukan rekomendasi investasi


Berikut adalah wujud implementasi antarmuka aplikasi web Sentilytics berdasarkan rancangan wireframe sebelumnya:

1. Implementasi Halaman Login Halaman ini merupakan hasil translasi dari rancangan wireframe login, di mana pengguna harus memasukkan kredensial yang valid sebelum dapat mengakses sistem utama.




Gambar 4.1 Implementasi Antarmuka Halaman Login

2. Implementasi Halaman Dashboard Utama Halaman ini mengimplementasikan rancangan kanvas utama yang merender grafik perbandingan harga aktual dan prediksi menggunakan Chart.js, serta menampilkan metrik evaluasi model.




Gambar 4.2 Implementasi Antarmuka Dashboard Utama

- Implementasi Halaman Admin Panel Halaman ini mengimplementasikan pembatasan akses (access control), di mana hanya pengguna dengan hak akses administrator yang dapat melihat ringkasan total pengguna terdaftar dan status model.



Gambar 4.3 Implementasi Antarmuka Halaman Admin Panel

- Implementasi Halaman Model Evaluation Halaman ini merealisasikan wireframe komparasi, menyajikan metrik RMSE, MAE, dan MAPE dari Model Baseline LSTM dan Model Hybrid LSTM secara berdampingan.




Gambar 4.4 Implementasi Antarmuka Halaman Model Evaluation

- Implementasi Halaman Forecast Simulation H+7 Pada fitur forecast H+7, sistem menampilkan hasil simulasi prediksi beberapa hari perdagangan ke depan. Untuk Model Hybrid LSTM, skor sentimen masa depan diasumsikan

menggunakan rata-rata skor sentimen tujuh hari terakhir. Nilai tersebut digunakan sebagai pendekatan karena data berita pada tanggal masa depan belum tersedia saat proses prediksi dilakukan. Forecast H+7 hanya digunakan sebagai fitur visualisasi tambahan dan tidak digunakan sebagai dasar utama evaluasi akurasi model.

Aplikasi web juga menampilkan disclaimer bahwa sistem tidak dimaksudkan sebagai rekomendasi investasi. Hal ini penting karena fokus penelitian berada pada penerapan Artificial Intelligence untuk prediksi dan visualisasi model, bukan pada pemberian keputusan investasi kepada pengguna.



Gambar 4.5 Implementasi Antarmuka Halaman Forecast Simulation H+7

6. Implementasi Halaman Dataset Summary Halaman ini merupakan implementasi dari wireframe transparansi data, menampilkan rincian dimensi himpunan data serta distribusi sentimen berita.

FILE	PATH	STATUS	SIZE
BBKA Stock Raw	data/raw/stock/BBKA_raw.csv	Available	43.6 KB
BBRI Stock Raw	data/raw/stock/BBRI_raw.csv	Available	45.7 KB
News Raw	data/raw/news/news_raw.csv	Available	302.1 KB
News Processed	data/processed/sentiment/news_processed.csv	Available	582.8 KB
BBKA Daily Sentiment	data/processed/sentiment/BBKA_daily_sentiment.csv	Available	19.9 KB
BBRI Daily Sentiment	data/processed/sentiment/BBRI_daily_sentiment.csv	Available	7.3 KB
BBKA Baseline Dataset	data/processed/fusion/BBKA_baseline_dataset.csv	Available	50.6 KB
BBKA Hybrid Dataset	data/processed/fusion/BBKA_hybrid_dataset.csv	Available	54.9 KB
BBRI Baseline Dataset	data/processed/fusion/BBRI_baseline_dataset.csv	Available	52.9 KB
BBRI Hybrid Dataset	data/processed/fusion/BBRI_hybrid_dataset.csv	Available	55.1 KB

Gambar 4.6 Implementasi Antarmuka Halaman Dataset Summary

4.2 Pengujian

Tahap pengujian dilakukan untuk memastikan bahwa model prediksi dan aplikasi web Sentilytics yang telah diimplementasikan dapat berjalan sesuai dengan rancangan penelitian. Pengujian pada penelitian ini terdiri dari dua bagian utama, yaitu pengujian model prediksi dan pengujian fungsionalitas sistem. Pengujian model prediksi dilakukan untuk mengetahui tingkat kesalahan Model Baseline LSTM dan Model Hybrid LSTM berdasarkan metrik RMSE, MAE, dan MAPE. Sementara itu, pengujian fungsionalitas sistem dilakukan menggunakan metode black-box testing untuk memastikan bahwa fitur-fitur utama pada aplikasi web dapat berjalan sesuai dengan kebutuhan pengguna.

Pengujian model difokuskan pada prediksi harga penutupan saham hari perdagangan berikutnya atau Close Price H+1. Hasil prediksi model dibandingkan dengan harga aktual pada data uji. Model dengan nilai RMSE, MAE, dan MAPE yang lebih rendah menunjukkan tingkat kesalahan prediksi yang lebih kecil. Adapun forecast H+7 pada dashboard Sentilytics tidak digunakan sebagai dasar evaluasi akurasi model, melainkan hanya sebagai fitur simulasi visualisasi.

4.2.1 Pengujian Model Prediksi

Pengujian model prediksi dilakukan terhadap dua emiten yang menjadi objek penelitian, yaitu BBKA dan BBRI. Setiap emiten diuji menggunakan dua skenario model, yaitu Model Baseline LSTM dan Model Hybrid LSTM. Model Baseline LSTM menggunakan fitur Open, High, Low, Close, dan Volume (OHLCV), sedangkan Model Hybrid LSTM menggunakan fitur OHLCV yang digabungkan dengan skor sentimen berita.

Data yang digunakan dalam pengujian merupakan data uji yang diperoleh dari pembagian data berdasarkan urutan waktu. Pembagian data dilakukan dengan rasio 80:20, yaitu 80% data awal digunakan sebagai data latih dan 20% data akhir digunakan sebagai data uji. Pendekatan ini digunakan untuk menjaga karakteristik data deret waktu dan menghindari terjadinya data leakage.

Metrik yang digunakan dalam pengujian model adalah Root Mean Square Error (RMSE), Mean Absolute Error (MAE), dan Mean Absolute Percentage Error (MAPE). RMSE digunakan untuk mengukur besarnya kesalahan prediksi dengan memberikan penalti lebih besar terhadap error yang tinggi. MAE digunakan untuk mengukur rata-rata selisih absolut antara harga aktual dan harga prediksi. MAPE digunakan untuk melihat tingkat kesalahan prediksi dalam bentuk persentase.

4.2.2 Hasil Evaluasi RMSE, MAE, dan MAPE

Hasil evaluasi Model Baseline LSTM dan Model Hybrid LSTM pada saham BBKA dan BBRI ditunjukkan pada Tabel 4.11.

Tabel 4.11 Hasil Evaluasi Model Baseline LSTM dan Hybrid LSTM

Emiten	Model	Fitur	RMSE	MAE	MAPE
BBKA	Baseline LSTM	OHLCV	172,4216	140,6926	1,4999
BBKA	Hybrid LSTM	OHLCV + Sentimen	168,0918	134,9102	1,4353
BBRI	Baseline LSTM	OHLCV	96,5722	83,233	2,1951
BBRI	Hybrid LSTM	OHLCV + Sentimen	96,2317	82,6312	2,1769

Berdasarkan Tabel 4.11, Model Hybrid LSTM pada saham BBKA memperoleh nilai RMSE sebesar 168,0918, MAE sebesar 134,9102, dan MAPE sebesar 1,4353. Nilai tersebut lebih rendah dibandingkan Model Baseline LSTM yang memperoleh RMSE sebesar 172,4216, MAE sebesar 140,6926, dan MAPE sebesar 1,4999. Hasil ini menunjukkan bahwa pada saham BBKA, penambahan fitur skor sentimen berita pada Model Hybrid LSTM dapat menurunkan tingkat kesalahan prediksi dibandingkan Model Baseline LSTM.

Pada saham BBRI, Model Hybrid LSTM memperoleh nilai RMSE sebesar 96,2317, MAE sebesar 82,6312, dan MAPE sebesar 2,1769. Nilai tersebut juga lebih rendah dibandingkan Model Baseline LSTM yang memperoleh RMSE sebesar 96,5722, MAE sebesar 83,2330, dan MAPE sebesar 2,1951. Dengan demikian, pada saham BBRI, Model Hybrid LSTM juga menunjukkan tingkat kesalahan prediksi yang lebih rendah dibandingkan Model Baseline LSTM.

Secara keseluruhan, hasil evaluasi menunjukkan bahwa Model Hybrid LSTM menghasilkan nilai RMSE, MAE, dan MAPE yang lebih rendah pada kedua emiten. Hal ini menunjukkan bahwa penambahan skor sentimen berita dapat membantu model dalam menurunkan tingkat kesalahan prediksi harga penutupan saham pada data uji. Namun, hasil tersebut berlaku pada dataset, periode pengamatan, dan konfigurasi model yang digunakan dalam penelitian ini.

4.2.3 Pengujian Fungsionalitas Sistem

Pengujian fungsionalitas sistem dilakukan menggunakan metode black-box testing. Pengujian ini berfokus pada kesesuaian fungsi sistem berdasarkan input dan output yang dihasilkan, tanpa meninjau struktur kode program secara langsung.

Pengujian dilakukan terhadap fitur utama aplikasi web Sentilytics, seperti login, register, dashboard, evaluasi model, forecast H+7, dataset summary, admin panel, pembatasan akses user biasa, logout, dan tampilan disclaimer.

Hasil pengujian black-box pada aplikasi web Sentilytics ditunjukkan pada Tabel 4.12.

Tabel 4.12 Hasil Pengujian Black-Box Aplikasi Sentilytics

No	Skenario Pengujian	Input / Aksi Pengguna	Hasil yang Diharapkan	Hasil Aktual	Status
1	Membuka halaman login	Pengguna mengakses halaman login	Sistem menampilkan halaman login	Halaman login berhasil ditampilkan	Berhasil
2	Melakukan registrasi akun baru	Pengguna mengisi form register dengan data valid	Sistem membuat akun baru dan menampilkan pesan berhasil atau mengarahkan ke halaman login	Akun baru berhasil dibuat	Berhasil
3	Login menggunakan akun valid	Pengguna memasukkan username/email dan password yang benar	Sistem menerima autentikasi dan mengarahkan pengguna ke dashboard	Pengguna berhasil masuk ke dashboard	Berhasil
4	Login menggunakan data salah	Pengguna memasukkan username/email atau password yang salah	Sistem menolak login dan menampilkan pesan kesalahan	Sistem menampilkan pesan kesalahan login	Berhasil
5	Logout dari sistem	Pengguna menekan tombol logout	Sistem mengakhiri sesi pengguna dan mengarahkan kembali ke halaman login	Sesi pengguna berhasil diakhiri	Berhasil
6	Akses admin panel oleh user biasa	User non-admin mencoba membuka halaman admin	Sistem menolak akses dan menampilkan halaman access denied / 403	Akses user biasa ditolak	Berhasil
7	Akses admin panel oleh admin	Admin login dan membuka halaman admin panel	Sistem menampilkan halaman admin panel	Admin panel berhasil ditampilkan	Berhasil

No	Skenario Pengujian	Input / Aksi Pengguna	Hasil yang Diharapkan	Hasil Aktual	Status
8	Menampilkan evaluasi BBCA Baseline LSTM	Pengguna memilih emiten BBCA dan model Baseline LSTM	Sistem menampilkan grafik actual vs predicted dan nilai RMSE, MAE, MAPE	Grafik dan metrik BBCA Baseline berhasil ditampilkan	Berhasil
9	Menampilkan evaluasi BBCA Hybrid LSTM	Pengguna memilih emiten BBCA dan model Hybrid LSTM	Sistem menampilkan grafik actual vs predicted dan nilai RMSE, MAE, MAPE	Grafik dan metrik BBCA Hybrid berhasil ditampilkan	Berhasil
10	Menampilkan evaluasi BBRI Baseline LSTM	Pengguna memilih emiten BBRI dan model Baseline LSTM	Sistem menampilkan grafik actual vs predicted dan nilai RMSE, MAE, MAPE	Grafik dan metrik BBRI Baseline berhasil ditampilkan	Berhasil
11	Menampilkan evaluasi BBRI Hybrid LSTM	Pengguna memilih emiten BBRI dan model Hybrid LSTM	Sistem menampilkan grafik actual vs predicted dan nilai RMSE, MAE, MAPE	Grafik dan metrik BBRI Hybrid berhasil ditampilkan	Berhasil
12	Menampilkan forecast H+7	Pengguna membuka halaman forecast atau memilih fitur forecast	Sistem menampilkan tabel dan grafik forecast H+1 sampai H+7	Forecast H+7 berhasil ditampilkan	Berhasil
13	Menampilkan dataset summary	Pengguna membuka halaman dataset summary	Sistem menampilkan ringkasan dataset harga saham, berita, sentimen, dan data fusion	Dataset summary berhasil ditampilkan	Berhasil
14	Menampilkan disclaimer sistem	Pengguna membuka dashboard atau halaman forecast	Sistem menampilkan keterangan bahwa aplikasi bukan rekomendasi investasi	Disclaimer berhasil ditampilkan	Berhasil

Berdasarkan hasil pengujian pada Tabel 4.12, seluruh skenario pengujian berhasil dijalankan sesuai dengan hasil yang diharapkan. Dengan demikian, aplikasi web Sentilytics telah memenuhi kebutuhan fungsional utama yang dirancang pada Bab 3. Hasil pengujian ini juga menunjukkan bahwa fitur autentikasi pengguna,

evaluasi model, forecast H+7, dataset summary, admin panel, dan disclaimer dapat berjalan sesuai fungsi yang dirancang.

4.2.4 Pembahasan Hasil Pengujian

Hasil evaluasi model menunjukkan bahwa Model Hybrid LSTM memperoleh nilai error yang lebih rendah dibandingkan Model Baseline LSTM pada kedua emiten. Pada saham BBKA, penurunan error terlihat pada seluruh metrik evaluasi, yaitu RMSE, MAE, dan MAPE. Hal yang sama juga terjadi pada saham BBRI, meskipun selisih penurunan error antara Model Baseline LSTM dan Model Hybrid LSTM tidak sebesar pada BBKA.

Perbedaan tingkat penurunan error antara BBKA dan BBRI dapat dipengaruhi oleh beberapa faktor, salah satunya adalah perbedaan jumlah data berita dan jumlah sentimen tidak nol pada masing-masing emiten. Berdasarkan hasil implementasi sebelumnya, jumlah berita dan jumlah sentimen tidak nol pada BBKA lebih banyak dibandingkan BBRI. Kondisi tersebut dapat menyebabkan fitur sentimen pada BBKA memiliki kontribusi yang lebih kuat dibandingkan pada BBRI.

Meskipun Model Hybrid LSTM menunjukkan nilai error yang lebih rendah, hasil penelitian ini tetap perlu dipahami sesuai ruang lingkup penelitian. Hasil evaluasi berlaku pada dataset, periode waktu, konfigurasi model, dan sumber berita yang digunakan. Oleh karena itu, penelitian ini tidak menyatakan bahwa Model Hybrid LSTM selalu lebih baik pada seluruh kondisi pasar atau seluruh emiten. Klaim yang dapat disampaikan adalah bahwa pada hasil eksperimen ini, penambahan skor sentimen berita membantu menurunkan tingkat kesalahan prediksi pada data uji BBKA dan BBRI.

Fitur forecast H+7 pada dashboard digunakan sebagai simulasi visualisasi. Pada Model Hybrid LSTM, skor sentimen masa depan diasumsikan menggunakan rata-rata skor sentimen tujuh hari terakhir karena data berita pada tanggal masa depan belum tersedia pada saat prediksi dilakukan. Forecast H+7 tidak digunakan untuk menghitung RMSE, MAE, dan MAPE karena tidak menjadi dasar utama evaluasi akurasi model. Evaluasi utama penelitian tetap dilakukan pada prediksi Close Price H+1 menggunakan data uji historis.

Dari sisi sistem, hasil black-box testing menunjukkan bahwa seluruh fitur utama aplikasi web dapat berjalan sesuai kebutuhan. Aplikasi dapat menampilkan halaman login, register, dashboard, evaluasi model, forecast H+7, dataset summary, admin panel, serta disclaimer bahwa sistem bukan rekomendasi investasi. Dengan demikian, aplikasi web Sentilytics dapat digunakan sebagai prototipe visualisasi hasil model prediksi berbasis Artificial Intelligence.

DAFTAR PUSTAKA

- Saputra, C. B., & Koesrindartoto, D. P. (2024). Pemanfaatan Analisis Sentimen Youtube untuk Prediksi Harga Saham: Studi pada Investor Retail Indonesia. *Jurnal Manajemen*, 21(1), 1–17. <https://doi.org/10.25170/jm.v21i1.5184>
- Krichen, M., Mihoub, A., Alzahrani, M. Y., Adoni, W. Y. H., & Nahhal, T. (2022). Are Formal Methods Applicable To Machine Learning And Artificial Intelligence? *Proceedings - 2022 2nd International Conference of Smart Systems and Emerging Technologies, SMARTTECH 2022*, 48–53. <https://doi.org/10.1109/SMARTTECH54121.2022.00025>
- Malik, A. (2024, September 30). *Saham BBRI, BBKA dan BMRI Kompak Turun, Begini Strategi Investasinya*. [Www.Bareksa.Com. https://www.bareksa.com/berita/saham/2024-09-30/saham-bbri-bbca-dan-bmri-kompak-turun-begini-strategi-investasinya](https://www.bareksa.com/berita/saham/2024-09-30/saham-bbri-bbca-dan-bmri-kompak-turun-begini-strategi-investasinya)
- Artana, I. K. A. B., Pradnyana, G. A., & Darmawiguna, I. G. M. (2023). ANALISIS SENTIMEN TWITTER UNTUK MENILAI KESIAPAN PEMBELAJARAN TATAP MUKA TERBATAS DENGAN INSET LEXICON DAN LEVENSHTAIN DISTANCE. *Jurnal Pendidikan Teknologi Dan Kejuruan*, 20(2), 200–209. <https://doi.org/10.23887/jptkuniksha.v20i2.64579>
- Abrar, E. H., Ariyanti, N., & Sumarno. (2026). Analisis Sentimen Ulasan Game Lokapala pada Google Play Menggunakan Algoritma SVM. *SMATIKA JURNAL*, 16(01), 157–164. <https://doi.org/10.32664/smatika.v16i01.2081>
- KB Valbury Sekuritas. (2025). *Company Report BBKA (PT Bank Central Asia TBK)*. <https://kbvalbury.com/cfind/source/files/bbca-9m25-results-211025.pdf>
- Kementrian Keuangan Republik Indonesia. (2024). *Siaran Pers Stabilitas Sistem Keuangan Tetap Terjaga di Tengah Dinamika Geopolitik Global dan Arah Pelonggaran Kebijakan Moneter*. <https://www.kemenkeu.go.id/informasi-publik/publikasi/siaran-pers/Siaran-Pers-Stabilitas-Sistem-Kuangan-%281%29>
- CNBC Indonesia. (2025, January 14). *Saham Bank Lagi Kurang Sehat, Apa yang Sebenarnya Terjadi?* <https://www.cnbcindonesia.com/research/20250114141133-128-603075/saham-bank-lagi-kurang-sehat-apa-yang-sebenarnya-terjadi>
- Suherlan, E., Arti, S., Nabilah, S., & Hazimah, Z. (2025). PENERAPAN FLASK FRAMEWORK UNTUK DEPLOYMENT MODEL MACHINE LEARNING DALAM Mendukung Analisis Adaptasi Mahasiswa Pada Pembelajaran Daring. *PINTER: Jurnal Pendidikan Teknik Informatika Dan Komputer*, 9(1), 110–117. <https://doi.org/10.21009/pinter.9.1.15>
- Liagkouras, K., & Metaxiotis, K. (2025). A Hybrid Long Short-Term Memory with a Sentiment Analysis System for Stock Market Forecasting. *Electronics (Switzerland)*, 14(14). <https://doi.org/10.3390/electronics14142753>
- Chaudhary, R. (2025). *Advanced Stock Market Prediction Using Long Short-Term Memory Networks: A Comprehensive Deep Learning Framework*. <https://doi.org/10.48550/arXiv.2505.05325>

- Amaliah, F., Kadek, I., & Nuryana, D. (2022). Perbandingan Akurasi Metode Lexicon Based Dan Naive Bayes Classifier Pada Analisis Sentimen Pendapat Masyarakat Terhadap Aplikasi Investasi Pada Media Twitter. *Journal of Informatics and Computer Science*, 03, 384–393. <https://doi.org/10.26740/jinacs.v3n03.p384-393>
- Ulfah, A., & Najiah, I. (2023). IMPLEMENTASI WEB SCRAPING PADA SITUS JURNAL SINTA MENGGUNAKAN FRAMEWORK SELENIUM WEBDRIVER PYTHON. *JIKA (Jurnal Informatika)*, 7(1), 29. <https://doi.org/10.31000/jika.v7i1.7037>
- Frensidy, B. (2023, January 9). *Tujuh Bias Behavioral Finance*. <https://feb.ui.ac.id/2023/01/12/budi-frensidy-tujuh-bias-behavioral-finance/>
- Joddy, S. (2025). *Comparative Analysis of CNN, LSTM, and CNN-LSTM for Indonesian Stock Prediction*. 7(3), 283–289. <https://doi.org/10.21512/emacsjournal.v6>

LAMPIRAN



Lampiran 1 Chart Harga Saham PT.Bank Rakyat Indonesia (BBRI)

Sumber: YahooFinance



Lampiran 2 Chart Harga Saham PT.Bank Central Asia (BBCA)

Sumber: YahooFinance